

基于时空动态图注意力网络的共享出行 用车需求预测研究与应用



重庆大学硕士学位论文 (专业学位)

学生姓名：骈纬国

指导教师：吴映波 教 授

专业学位类别：工程（车辆工程）

研究方向：汽车智能化与人机交互技术

答辩委员会主席：熊庆宇 教 授

授位时间：2021 年 6 月

Research and Application of Spatial-Temporal Dynamic Graph Attention Network Based Sharing Travel Vehicle Usage Demand Prediction



A Thesis Submitted to Chongqing University
in Partial Fulfillment of the Requirement for
Master of Engineering

By

Pian Weiguo

Supervised by Prof. Wu Yingbo

June, 2021

摘 要

共享出行作为一种新型的出行方式，在出行服务市场、智能交通和车联网系统中占据着越来越重要的地位，为人们的日常出行提供了更多的便利性。共享出行用车需求预测是解决共享出行系统中车辆分布与用户需求不匹配问题的有效解决办法。准确的需求预测模型可以协助平台进行资源的预分配，以此来提高车辆使用率和用户体验。作为时空数据挖掘中的一项重要任务，共享出行用车需求预测吸引了智能交通和车联网领域研究人员的广泛关注。最新的相关研究工作主要是基于图卷积网络（Graph Convolutional Network, GCN）来为复杂的非欧氏空间相关性进行建模。但是，现有的基于 GCN 的共享出行需求预测方法在提取空间相关性特征时，难以为不同的邻居区域分配不同的重要性系数。此外，这些方法所操作的图结构，是在时间线上的不同时间间隔中保持固定的静态空间图结构，不具有时间特定性，因此难以提取具有时间特定性的动态空间关联性特征。本文提出了用于共享出行用车需求预测的时空动态图注意力网络（Spatial-Temporal Dynamic Graph Attention Network, STDGAT）。基于图注意力网络（Graph Attention Network, GAT）的注意力机制，STDGAT 能够在不同的邻居区域对之间建立不同的空间相关性，以此实现了自适应邻居区域重要性分配。此外，本文还设计了一种基于通勤关系的具有时间特定性的动态空间图结构，并以此为基础在时间线上的不同时间间隔中捕获具有时间特定性的动态空间相关性特征。本文在大规模的共享出行数据集上进行了实验，实验结果表明，本文所提出的方法在 RMSE、MAPE 和 MAE 三个评价指标上均优于现有最先进的方法。最后，本文基于所提出的方法，设计并实现了共享出行用车需求预测系统原型。

本文的主要工作内容如下：

- ① 本文介绍了共享出行用车需求预测的研究背景及意义，对国内外相关研究工作进行了总结。
- ② 本文提出了用于共享出行用车需求预测的 STDGAT 方法。该方法利用 GAT 的注意力机制，实现了自适应邻居区域重要性分配。
- ③ 本文提出了一种基于通勤关系的时间特定性动态空间图结构。通过这种空间图结构，模型实现了在不同的时间间隔中动态的提取具有时间特定性的空间相关性特征。
- ④ 本文在一个大规模的共享出行需求数据集上进行了大量的实验，实验结果证明了本文所提出的方法在 RMSE、MAPE 和 MAE 三个评价指标上均优于相关基准比较方法。

⑤ 本文基于所提出的 STDGAT 方法，设计并实现了 STDGAT 共享出行用车需求预测系统原型。

关键词：用车需求预测；深度学习；时空数据预测；图神经网络；共享出行

Abstract

As a novel travel mode, sharing travel plays a more and more important role in the travel service market and intelligent transportation system, which provides people more convenience in their daily travel. Sharing travel vehicle usage demand prediction is an effective solution to the mismatch problem between the distribution of vehicles and user demand in sharing travel systems. An accurate demand prediction model can help platforms pre-allocate resources to improve vehicle utilization and user experience. As an essential task in spatial-temporal data mining, sharing travel vehicle usage demand prediction has attracted extensive attention of researchers in the field of intelligent transportation. Recent related works mainly focus on Graph Convolutional Networks (GCN) to model the complicated irregular non-Euclidean spatial correlations. However, existing GCN-based sharing travel vehicle usage demand prediction methods only assign the same importance to different neighbor regions, and maintain a fixed graph structure with static spatial relationships throughout the timeline when extracting the irregular non-Euclidean spatial correlations. This paper proposes the Spatial-Temporal Dynamic Graph Attention Network (STDGAT), a novel sharing travel vehicle usage demand prediction method. Based on the attention mechanism of GAT, STDGAT extracts different pair-wise correlations to achieve the adaptive importance allocation for different neighbor regions. STDGAT constructs a novel time-specific commuting-based dynamic spatial graph structure to capture the dynamic time-specific spatial relationships throughout the timeline. Extensive experiments are conducted on a real-world sharing travel dataset, and the experimental results demonstrate the significant improvement of our method on three evaluation metrics RMSE, MAPE and MAE over state-of-the-art baselines. Finally, this paper designs and implements a sharing travel vehicle usage demand prediction prototype system based on the proposed STDGAT.

The main work of this paper can be summarized as follows:

- ① This paper introduces the background and significance of sharing travel vehicle usage demand prediction, and summarizes recent related works.
- ② This paper proposes the STDGAT, a novel sharing travel vehicle usage demand prediction method. Based on the GAT, STDGAT achieves adaptive importance assignment for different neighbor regions.

③ This paper proposes a time-specific commuting-based dynamic spatial graph structure. By this way, STDGAT can capture the dynamic time-specific spatial features in different time intervals throughout the timeline.

④ This paper conducts extensive experiments on a large-scale real-world sharing travel dataset. The experimental results show the superiorities of our method on three evaluation metrics RMSE, MAPE and MAE, compared with state-of-the-art baselines.

⑤ Based on the proposed STDGAT, a sharing travel vehicle usage demand prediction system prototype is designed and implemented.

Keywords: Vehicle usage demand prediction; deep learning; spatial-temporal prediction; graph neural network; sharing travel

目 录

中文摘要.....	I
英文摘要.....	III
1 绪 论.....	1
1.1 课题研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 共享出行中的用车问题研究现状.....	2
1.2.2 时空预测研究现状.....	2
1.2.3 图神经网络研究现状.....	4
1.3 本文的主要工作.....	4
1.4 本文的组织结构.....	5
2 自适应动态空间相关性建模与数据的时空预处理.....	6
2.1 共享出行中的用车需求预测问题定义.....	6
2.2 现有时空特征提取方法.....	7
2.2.1 基于卷积神经网络的城市空间特征提取方法.....	7
2.2.2 基于循环神经网络的时间特征提取方法.....	7
2.2.3 基于图卷积神经网络的城市空间特征提取方法.....	8
2.3 自适应动态空间相关性建模.....	9
2.3.1 基于图注意力网络的自适应空间相关性.....	9
2.3.2 基于通勤关系的动态空间图结构.....	12
2.4 数据的时空预处理.....	14
2.4.1 原始数据信息.....	14
2.4.2 数据的时间预处理.....	15
2.4.3 数据的空间预处理.....	16
2.5 本章小结.....	16
3 基于时空动态图注意力网络的共享出行用车需求预测模型.....	17
3.1 模型整体结构.....	17
3.2 空间模块.....	17
3.3 时间模块.....	19
3.4 输出预测层.....	20
3.5 本章小结.....	20
4 共享出行用车需求预测实验结果与分析.....	21

4.1 实验细节设置.....	21
4.1.1 模型参数设置.....	21
4.1.2 实验数据设置.....	21
4.1.3 损失函数.....	21
4.1.4 性能度量指标.....	21
4.2 基准方法.....	22
4.3 与基准方法实验结果的对比与分析.....	23
4.4 不同时间段上的实验结果的对比与分析.....	25
4.4.1 工作日与周末的实验结果对比.....	25
4.4.2 一周中不同天上的实验结果对比.....	27
4.5 不同模块上的实验结果.....	32
4.5.1 空间模块上的实验结果.....	32
4.5.2 时间模块上的实验结果.....	33
4.6 动态图结构对实验结果的影响.....	33
4.7 输入序列长度与 GAT 层数对实验结果的影响.....	34
4.7.1 序列长度对实验结果的影响.....	34
4.7.2 GAT 层数对实验结果的影响.....	35
4.8 时间消耗和损失值变化.....	36
4.8.1 模型训练和验证阶段的损失值变化.....	36
4.8.2 模型训练和验证阶段的时间损耗.....	36
4.9 本章小结.....	37
5 共享出行用车需求预测系统原型.....	38
5.1 需求分析.....	38
5.2 系统架构及功能模块设计.....	38
5.3 数据库设计.....	40
5.4 应用原型实现与分析.....	42
5.5 本章小结.....	44
6 总结与展望.....	45
6.1 总结.....	45
6.2 展望.....	46
参考文献.....	47
附 录.....	52
A. 作者在攻读硕士学位期间发表的论文目录.....	52
B. 作者在攻读硕士学位期间参与的科研项目.....	52

C. 学位论文数据集.....	53
致 谢.....	54

1 绪 论

1.1 课题研究背景及意义

出行服务作为城市交通中最重要的服务之一，在人们的日常生活中扮演着不可或缺的角色。随着社会的发展与城市人口数量的不断增长，人们对于出行服务的需求不断增长，导致传统的出行服务已难以满足人们日常的出行需要。近年来，随着移动互联网和共享经济在全球的迅速发展，共享出行开始出现在人们的视野中，并逐渐在出行服务市场中占据了重要的地位，为人们的日常出行提供了前所未有的便利性。不同于传统的出行服务，共享出行主要以共享和合乘的方式来为用户提供车辆，并借助互联网平台，以网约车、共享汽车、共享单车等方式来为用户提供共享性的车辆资源，其中，以滴滴出行、Uber、Grab、长安出行等公司的共享出行平台为代表，为人们带来了更好的出行体验。

随着这些共享出行平台的飞速发展，平台资源（车辆）与用户数量不断扩大，一些低效的运营问题逐渐出现在平台中^[1]，即平台车辆的分布往往与用户的需求不匹配。这是由于用户的需求是随着时间而变化的，在无法提前预知用户的用车需求的情况下，平台很难产生高效的车辆调度与预分配方案。在这种情况下，经常会出现用户等待时间较长^[2]、空载车辆过多^[3]等问题。另一方面，低效的平台运营与车辆调度，还会造成交通堵塞等问题。因此，一个准确的用车需求预测方法可以有效的协助平台分配车辆、提高车辆利用率、减少用户等待时间、缓解交通堵塞等问题^[4]，这对于共享出行平台的建设与发展是至关重要的。

共享出行平台作为当今社会中智能交通与车联网系统的一个重要组成部分，对其资源运营分配的持续优化是有必要的，这对于构建更加智能化的交通系统有着巨大的帮助与推动性作用。在近些年智能交通与车联网系统领域中，需求预测已成为交通预测中的一个重要问题，国内外学者针对类似的预测问题做出了许多研究，包括交通流量预测、出租车需求预测等。在一些传统的方法中，学者们通常使用统计学模型来解决这类问题^{[5][6][7]}。近年来，随着深度学习的飞速发展，诸多人工智能领域获得了更加有效的解决方法，例如计算机视觉、自然语言处理等。深度学习的成功带来了其他领域研究人员大量的启发，其中，在交通领域中，学者们已经广泛的应用了深度学习方法来建立预测模型。在这些方法中，学者们构建了时空模型来进行城市空间与时间上的建模，以此获得了更加合理的建模方式。在此基础上，研究人员做出了许多具有开创性的时空预测经典方法，例如用于交通流量预测的 DeepST^[8]、ST-ResNet^[9]，用于出租车需求预测的 DMVST-Net^[10]等，这也得益于近些年来共享出行公司的崛起，从而收集并构建了大规模的数据

以供模型训练。在这些工作的基础上，越来越多的学者探索了更加先进的深度学习模型来进一步解决这些问题。以此可以看出，时空预测问题已成为深度学习在交通领域中最重要任务之一。作为时空预测中的一个重要组成部分，需求预测具有极高的学术和应用价值。

1.2 国内外研究现状

1.2.1 共享出行中的用车问题研究现状

随着共享出行的崛起，共享出行中的用车问题引起了越来越多相关研究人员的关注。共享出行中的用车问题主要分为用车预测和车辆调度问题。这些研究任务的最终目的在于提高车辆的利用率和平台的运营效率。张雅洁等人^[11]提出了用于共享出行的站点出行预测方法。顾天奇等人^[12]提出了一种共享出行用车总量预测方法。Geng 等人^[4]提出了基于图卷积网络 (Graph Convolutional Network, GCN) 的深度学习模型，用于共享出行区域级用车需求预测。Singhvi 等人^[13]提出了用于共享单车系统的车辆使用量预测方法。Lin 等人^[14]基于图卷积网络 (Convolutional Neural Network, CNN)，提出了用于共享出行站点级用车需求预测的深度学习方法。Luo 等人^[15]提出了一个用于共享汽车用车需求预测的数据驱动方法。Xiao 等人^[16]提出了用于共享单车需求预测的时空图卷积网络。

除了上述预测问题外，研究人员在共享出行中的车辆调度问题中也做了大量的研究工作。周龙雨等人^[17]提出了基于 BP 神经网络的共享单车调度优化方法。丁梓文等人^[18]对共享汽车的优化调度策略进行了相关研究工作。Liu 等人^[19]为了平衡共享出行系统中的资源（车辆），提出了一个基于多源数据的智能优化方法。Mao 等人^[20]基于时空图，提出了一个动态的共享出行车辆调度模型。Dickerson 等人^[21]通过对可重复使用的离线资源进行在线匹配的方式，对共享出行平台中的车辆分配问题进行了优化。Li 等人^[22]提出了一个时空强化学习方法来对共享出行系统中的车辆进行调度。Zhu 等人^[23]提出了一种用于共享出行的车辆在线路径规划算法。Pan 等人^[24]提出了一种深度强化学习方法来针对无桩共享单车系统中的资源调度平衡问题。

1.2.2 时空预测研究现状

时空预测是智能交通中的一项重要研究工作，这项研究工作包含了多个交通相关的预测任务，例如车流量预测、目的地预测、需求预测（本文中的预测任务）等。这些预测任务的方法是相似的，具体而言，在这些方法中，人们利用过去的一些连续时间点上的数据来构建时间序列来预测未来一个或多个时间点上数据，其中每个时间点上数据都具有空间特征，以此来建立时空模型^{[8][9][10][25]}。一些传统的方法主要依赖于时间序列中的周期性信息来回归得到最终的预测结果，例如，

最具代表性的方法为自回归移动平均模型 (Autoregressive Integrated Moving Average, ARIMA)。ARIMA 在一些传统的交通预测任务中得到了广泛的应用^{[6][7]}。此外,在其他的相关研究工作中,一些额外的信息也被用来辅助模型的预测过程,以此来提高模型的预测准确率,例如天气状况和节假日信息等^{[26][27][28]}。

在最近的时空预测相关研究工作中,研究人员开始广泛应用深度学习方法来建立模型。Zhang 等人^[8]提出了一个基于深度神经网络的模型来预测城市交通流量,在此之后,他们进一步将残差连接^[29]加入到了他们的模型中,并提出了用于城市交通流量预测的 ST-ResNet^[9]。Wang 等人^[25]使用了带有残差连接的多层全连接神经网络,并使用了天气、节假日等信息作为额外特征输入,来预测多个区域中出租车供需之间的差距。此外,一些使用长短期记忆网络(Long Short-Term Memory, LSTM)和双向长短期记忆网络(Bi-directional Long Short-Term Memory, BiLSTM)来对时间信息进行编码的方法也被提出,并被用于交通预测和目的地预测中^{[30][31]}。Yao 等人^[10]将卷积神经网络(Convolutional Neural Network, CNN)和循环神经网络(Recurrent Neural Network, RNN)结合到同一个模型中来提取联合时空特征,并在此基础上使用了图嵌入(Graph Embedding)方法来获取远距离区域之间的语义相关性特征。Qiu 等人^[32]受 non-local 网络^[33]的启发,提出了一个用于出租车起始点-终点需求预测的情景化时空网络。马君等人^[34]基于神经网络,对城市交通流量预测进行了研究。佟健颀等人^[35]使用深度残差网络构建了用于短时交通流量预测的模型。徐彤坤等人^[36]基于大数据技术,对出租车需求预测和拼车算法进行了深入的研究。段宗涛等人^[37]使用 CNN、LSTM 和 ResNet 构建了一个用于出租车需求预测的深度学习模型。

尽管上述方法在时空预测问题中取得了不错的效果,但由于这些方法在提取空间关联性时仅仅使用了卷积神经网络,因此这些方法无法对非欧几里得空间关联性进行建模。针对非欧氏空间关联性的建模,李小妍等人^[38]基于图神经网络(Graph Neural Network, GNN),提出了一个交通流量预测模型。Yu 等人^[39]提出了基于图卷积神经网络(Graph Convolutional Network, GCN)的 STGCN 模型,该方法首次使用了 GCN 来对非欧氏空间相关性进行建模,并使用 1-d 卷积构建了一个时间特征提取模块。在这之后, Geng 等人^[4]构建了基于邻域关系、功能相似性和交通连通性的多图模型结构,以此来捕获更加多样性的非欧氏空间相关性结构,并使用 RNN 来对时间依赖性进行了建模。但是,上述基于 GCN 的非欧氏空间相关性建模方法都存在一个问题,即在对邻居区域进行空间相关性建模时,无法自适应的对不同的邻居区域建立不同的空间依赖性关系,这是由于传统的 GCN 模型对于一个节点的不同邻居节点,只能分配相同的权重关系。此外,现有的基于图神经网络的方法在时间线上的不同时间点中进行空间建模时,只使用了固定

的图结构来对空间进行建模，这种静态的图结构不足以对随着时间而变化的动态空间相关性进行建模。

1.2.3 图神经网络研究现状

传统的深度学习模型已经被广泛应用于多种研究领域，例如卷积神经网络（Convolutional Neural Network, CNN）在计算机视觉领域中的应用^[40]和循环神经网络在自然语言处理领域中的应用^[41]。但是，在一些特定的任务中，这些传统的深度学习方法并不能取得很好的效果，例如对于非标准网格状数据结构，即非欧氏数据结构的建模中。因此，基于图结构的图神经网络（Graph Neural Network, GNN）应运而生，并被广泛应用于社交网络^[42]、计算机视觉^{[43][44]}、时空预测^{[41][39]}等研究领域中。

最早的图神经网络是由 Gori 等人^[45]和 Scarselli 等人^[46]提出来，用于处理具有一般性和通用性的图数据结构。在这之后，人们开始尝试将用于标准欧氏数据结构的卷积操作推广到图结构上来。Bruna 等人^[47]提出了一种基于图拉普拉斯矩阵的通用性图卷积网络（Graph Convolutional Network, GCN）。随后，Defferrard 等人^[48]在 Bruna 等人工作的基础上，提出了一种基于切比雪夫多项式的方法来优化特征值分解的过程，以此来进一步优化 GCN。在这些工作的基础上，Kipf 等人^[49]将滤波器限制在图中每个节点的一阶近邻上，以此来进一步简化了图卷积操作。在这之后，基于注意力机制（Attention Mechanism）的图注意力网络（Graph Attention Network, GAT）被 Veličković 等人^[50]提出，并以此实现了对邻居节点的自适应权重分配。

1.3 本文的主要工作

为了能够准确的预测出共享出行中的用车需求，并将预测结果应用到共享出行平台的用车需求预测系统中，本文主要做了如下工作：

①本文提出了一个由空间模块和时间模块组成的网络结构，时空动态图注意力网络（Spatial-Temporal Dynamic Graph Attention Network, STDGAT）。其中，在 STDGAT 的空间模块中，本文使用了图注意力网络（Graph Attention Network, GAT）来对空间相关性进行建模，并利用了 GAT 的注意力机制（Attention mechanism）实现了对邻居区域的自适应重要性分配，以此来为不同的邻居区域建立不同的非欧氏空间相关性。此外，本文构建了一种基于实际通勤关系的时间特定性动态空间图结构，并以此为基础，使 STDGAT 在不同的时间点上，能够为每个节点（区域）动态的选择邻居节点（区域），以此来捕获具有时间特定性的动态空间相关性特征。同时，本文在 STDGAT 的时间模块中，使用了长短期记忆网络（Long Short-Term Memory, LSTM）来对时间依赖性进行建模。

②本文在大规模的共享出行用车需求数据集上进行了大量的实验，并与现有的前沿方法进行了对比。实验结果证明 **STDGAT** 的性能优于现有的前沿方法且具有很好的合理性与鲁棒性。

③本文以 **STDGAT** 方法为基础，设计并建立了一个共享出行用车需求预测系统原型。

1.4 本文的组织结构

本文的具体结构安排如下：

第一章：绪论。主要介绍了本课题的研究背景和研究意义，并详细分析了共享出行中的用车问题研究现状、时空预测的研究现状和图神经网络的研究现状，最后在本章节的最后详细阐述了本文的主要工作和本文的组织结构。

第二章：自适应动态空间相关性建模与数据的时空预处理。本章节首先对共享出行中的用车需求预测问题进行了符号化和数学化的定义，然后对现有的时空特征提取方法进行了详细的描述，分别为基于卷积神经网络的空间特征提取方法、基于循环神经网络的时间特征提取方法、基于图卷积网络的空间特征提取方法。随后对本文所提出的自适应动态空间相关性（基于图注意力网络的自适应空间相关性和基于通勤关系的动态空间图结构）进行了详细的阐述，最后对本文所使用的数据集进行了描述并介绍了对其进行的时空预处理方法。

第三章：基于时空动态图注意力网络的共享出行用车需求预测模型。本章节对模型的整体结构和各组成模块进行了详细的描述。

第四章：共享出行用车需求预测实验结果与分析。本章节详细阐述了实验的细节设置，并介绍了本文中的所有基准模型。该章节的后续部分包括了所有实验结果与对实验结果分析。

第五章：基于时空动态图注意力网络的共享出行用车需求预测系统原型。本章节基于本文所提出的时空动态图注意力网络（**Spatial-Temporal Dynamic Graph Attention Network, STDGAT**），设计并实现了一个共享出行用车需求预测系统原型，并介绍了系统的需求、设计与实现。

第六章：总结与展望。本章节对本文的主要工作进行了总结，并针对未来可进一步进行的研究工作进行了展望。

2 自适应动态空间相关性建模与数据的时空预处理

2.1 共享出行中的用车需求预测问题定义

在本小节首先定义了一些符号化的概念，然后基于这些概念对共享出行中的用车需求问题进行公式化解释和定义。

基于文献^{[9][10]}中问题定义方式，本文首先定义了城市中所需预测的区域集合，如公式(2.1)所示：

$$R = \{r_1, r_2, r_3, \dots, r_N\} \quad (2.1)$$

其中， N 表示所需预测的区域总数， $r_i, i \in 1, 2, 3, \dots, N$ 表示单个区域。本文按照相关文献^{[4][10][32]}中的城市分割方式，根据真实的地理坐标（经度和纬度）对整个城市进行分割来构建各个区域，因此每个区域的真实形状是规则的矩形，并被抽象成一个点来进行建模。

对于时间维度上的信息分割，假设数据集中包含 D 天，并且每天可以被划分为 H 个时间间隔，则数据集中共包含 $H \times D$ 个时间间隔。基于该假设，本文定义了所有时间间隔的集合：

$$T = \{t_0, t_1, t_2, \dots, t_{(H \times D)-1}\} \quad (2.2)$$

基于公式(2.1)和公式(2.2)，本文进一步定义了如下概念：

- **共享出行用车订单：**共享出行用车订单被定义为一个二元组 $\langle o.r, o.t \rangle$ ，其中 $o.r$ 表示用户请求该订单时所处的区域， $o.t$ 表示用户请求订单时所处的相应时间间隔。
- **共享出行用车需求：**区域 r 在时间间隔 t 中的共享出行用车需求被定义为在时间间隔 t 中，区域 r 的用车订单总量，在本文中用符号 $x'_r \in \mathbb{N}$ 表示。因此，在时间间隔 t 中，区域集合 R 中的需求可以表示为向量 $X^t \in \mathbb{N}^N$ ，其中， X^t 中的每个元素即为 $x'_r, r \in R$ ， N 表示区域集合 R 中区域的数量。
- **共享出行中的用车需求预测：**共享出行中的需求预测任务是一项基于历史数据的时间序列预测任务，具体而言，是根据过去多个连续时间间隔中的需求序列数据来预测未来一个时间间隔中的全局需求量的任务。其中给定的历史需求序列从时间间隔 $t-L+1$ 到当前时间间隔 t 。在本文中，这项预测任务如公式(2.3)所示：

$$X^{t+1} = \mathcal{F}(\{X^{t-L+1}, \dots, X^{t-1}, X^t\}) \quad (2.3)$$

其中， L 表示输入序列长度， $\mathcal{F}(\cdot)$ 表示预测模型。

由于本文所提出的预测模型是基于图神经网络进行建模的，因此在本文中，

输入到模型中的需求序列中的每个元素 X^t 是图结构的。具体而言，城市结构图 $G=(V,E,A)$ 表示城市中区域的空间图结构，在图 G 中，每个节点 $v_r \in V$ 代表了一个区域 r ，并且区域 r 在时间间隔 t 中的需求量 x_r^t 即为节点 v_r 在时间间隔 t 中的特征值。因此，在本文中，基于图神经网络的共享出行用车需求预测任务可以表示为：

$$X^{t+1} = \mathcal{F}(\{(X^{t-L+1}, G), \dots, (X^{t-1}, G), (X^t, G)\}) \quad (2.4)$$

2.2 现有时空特征提取方法

2.2.1 基于卷积神经网络的城市空间特征提取方法

卷积神经网络（Convolutional Neural Network, CNN）在空间相关性建模中取得了良好的效果，并在多个领域中得到了广泛的应用，例如计算机视觉中的图像特征提取^{[29][40][51]}、智能交通中的城市空间相关性建模等^{[8][9][10][28][32]}。

在城市空间相关性建模中，CNN 往往被用来提取城市空间特征。具体而言，在提取城市空间特征时，CNN 将输入到模型中的城市矩阵进行卷积操作，得到一个具备更大感受野的特征矩阵，并将其输出到下一层中。其中，输入到模型中的城市矩阵中每一个值，代表了城市中一个区域或站点的相应特征值，例如需求量、车流量等。基于 CNN 的城市空间特征提取如公式(2.5)所示：

$$X_{l+1} = X_l * W_l + b_l \quad (2.5)$$

其中， X_l 表示第 l 层的特征矩阵， W_l 表示第 l 个卷积层的权重， b_l 表示第 l 个卷积层的偏置值， $*$ 表示卷积操作。需要注意的是，输入到第一个卷积层的特征矩阵中的值，往往是真实的特征值，例如真实的需求量、真实的车流量、真实的客流量等。此外，输入到第一个卷积层的特征矩阵的维度值（矩阵的长乘以矩阵的宽）往往代表城市中区域或站点的总数，并且矩阵中元素的位置往往是按照其对应的区域或站点在城市中真实的地理分布来进行排布的。

此外，由于在时空预测中，输入到模型的数据为序列数据，因此时空预测中的空间特征提取过程需要对时间序列中每个时间点上的数据分别进行空间特征的提取，即：

$$X_{l+1}^t = X_l^t * W_l + b_l, t \in 0, 1, 2, \dots, T \quad (2.6)$$

其中， T 表示输入到模型的序列长度，即用于预测未来的过去连续时间间隔数。

2.2.2 基于循环神经网络的时间特征提取方法

循环神经网络（Recurrent Neural Network, RNN）在序列相关研究领域中取得了优异的性能^[41]，包括自然语言处理领域^{[52][53]}、时空数据挖掘领域^{[4][10][31][32]}等。由于 RNN 可以将序列中不同位置间的依赖性和特征进行建模和提取，因此，RNN

被广泛应用于时间依赖性建模中，以此来将过去的信息与当前的信息进行联合建模，提取时间特征。

基于 RNN 的时间特征提取可以表示为：

$$h_t = RNN(x_t, h_{t-1}), t \in 0, 1, 2, \dots, T \quad (2.7)$$

其中， x_t 表示在 t 时刻输入到 RNN 的数据， h_t 表示在 t 时刻 RNN 的输出隐藏状态，即为到当前时刻为止，从过去的输入序列中提取到的时间特征。 T 表示输入到 RNN 中的序列的总长度，即用来预测未来时间点上数据的过去的时间点数。

2.2.3 基于图卷积网络的城市空间特征提取方法

传统的卷积神经网络在处理标准的网格状欧氏数据结构时具有优异的效果，但是，传统的 CNN 具有难以处理非欧氏数据结构的缺点。图卷积网络（Graph Convolutional Network, GCN）的提出，解决了传统 CNN 无法处理非欧氏数据结构的缺点。不同于传统的卷积神经网络，GCN 是一种定义在图结构上，用来对非欧氏数据结构进行卷积操作的神经网络结构。

具体而言，被 GCN 所操作的图被定义为 $G = (V, E, A)$ ，其中， V 和 E 分别表示图 G 中所有的节点和边的集合。 $A \in \mathbb{R}^{|V| \times |V|}$ 表示图 G 的邻接矩阵。

当前较为流行的一种将卷积操作运用到图结构上的 GCN 模型是由 Defferrard 等人^[48]提出的，这种 GCN 模型基于切比雪夫多项式来定义卷积操作，如公式(2.8)所示：

$$x' = \sigma\left(\sum_{j=0}^{K-1} \alpha_j L^j x\right) \quad (2.8)$$

其中， x 表示图中某个节点的特征值或特征向量， $(\alpha_0, \alpha_1, \dots, \alpha_{K-1})$ 是模型可学习的因数， L^j 表示图 G 的第 j 阶拉普拉斯矩阵， $\sigma(\cdot)$ 是非线性单元，即激活函数。在公式(2.9)中，图拉普拉斯矩阵可以表示为：

$$L = I - D^{-1/2} A D^{-1/2} \quad (2.9)$$

其中， $I \in \mathbb{R}^{|V| \times |V|}$ 表示维度为 V 的单位矩阵， D 表示图 G 的度矩阵。但是，由于需要对连续 K 阶的拉普拉斯矩阵和切比雪夫多项式进行求和运算，因此，上述图卷积操作的计算量和计算复杂度较高。为了进一步简化图卷积操作，Kipf 等人^[49]在上述 GCN 理论的基础上使用图拉普拉斯的一阶近似来叠加多个局部化图卷积层，以此定义了一个层级的图卷积公式。通过这种方式，GCN 层的卷积公式可以表示为：

$$x' = \sigma(W \tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} x) \quad (2.10)$$

其中， W 是该 GCN 中实际可训练的参数矩阵， \tilde{A} 和 \tilde{D} 是归一化后的邻接矩阵和度矩阵，其中 $\tilde{A} = A + I$ ， $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$ 。通过这种方式，GCN 中的近似阶数被限

制为 1，因此，该 GCN 层可以有效的减少需要学习的参数量，这可以使大规模的图计算更加高效与便捷。

基于上述图卷积理论，空间特征提取可以扩展到非欧氏的空间关联性建模上，即空间特征的提取不再局限于在标准的网格状区域数据上对相邻区域进行建模。此外，在时空预测中，由于空间特征需要在时间序列中的不同时间点上分别提取，因此，基于图卷积网络的城市空间特征提取可以表示为：

$$M_{l+1}^t = \sigma(W\tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2}M_l^t), t \in 0, 1, 2, \dots, T \quad (2.11)$$

其中， T 表示用来预测未来时间点的输入序列的长度， l 表示当前图卷积层的层数。 $M \in \mathbb{R}^{|V| \times n}$ 表示输入到图卷积层的特征矩阵，其中， $|V|$ 表示图 G 中节点的个数，即区域的总数， n 表示每个节点（区域）在当前层的特征向量的长度，在第一个层中， n 等于 1，即每个区域的特征是一个具体的特征值（需求量，流量）。

2.3 自适应动态空间相关性建模

现有的时空预测方法虽然可以提取空间特征和时间特征来组成联合时空特征，并以此来进行预测。但是，这些方法在提取空间特征时，对于不同的区域对之间的建模方式是相同的，因而忽略了一个重要的因素——不同区域对之间具有不同的空间关联性。因此，现有方法在提取空间特征时，难以使每个区域为其不同的邻居区域建立不同的重要性关系。此外，现有方法在不同时间间隔中，使用了固定的图结构来提取空间特征，因此而忽略了一个重要的上下文信息——空间关联性在不同的时间间隔中是不同的，即空间关联性应是一种具有时间特定性的动态关联性关系。

本文针对这两个问题对现有方法进行了改进，并提出了自适应空间关联性和动态空间关联性的建模方法。详细内容如下文所示。

2.3.1 基于图注意力网络的自适应空间相关性

对于城市中区域间的空间特征提取过程，本文认为不同的区域对之间的关联性是不同的。例如，图 2.1 是一个城市区域图的例子，其中区域 A 、 B 、 C 分别是商业区、住宅区和公园，对于区域 A （商业区）来说，区域 B （住宅区）和区域 C （公园）对其的影响程度是不同的，即从用车需求上来说，住宅区对商业区的影响程度高于公园对商业区的影响程度。因为商业区与住宅区之间的用车需求量往往是大于与公园之间的用车需求量。因此，在空间相关性建模时，区域 A （商业区）和区域 B （住宅区）之间的建模关系应该与区域 A （商业区）和区域 C （公园）之间的建模关系有所不同，即区域 A （商业区）应对区域 B （住宅区）和区域 C （公园）建立不同的重要性联系。



图 2.1 城市区域图

Figure 2.1 Region Map in Urban

基于传统 GCN 的空间特征提取方法是基于图拉普拉斯矩阵的邻居节点聚合，这种特征提取方式存在一个缺陷，即图中每个节点在聚合邻居节点的特征时，对不同的邻居节点分配的是相同的权重，这样也就造成了一个问题，即对于一个节点来说，其为不同的邻居节点分配的重要性是相同的。这种方式在城市空间相关性建模与城市空间特征提取中显然是不够合理的，因为这种方式无法为不同的区域对之间建立不同的重要性联系。为了解决这个问题，本文使用图注意力网络（Graph Attention Network, GAT）^[50]来对城市中区域间的空间相关性进行建模。

GAT 是一种基于注意力机制（Attention Mechanism）^{[52][53][54][55][56][57]}的更加先进的图卷积网络。其中，图注意力层（Graph Attention Layer, GAT 层）是构成 GAT 的基础层结构，被用来学习图中节点间的注意力因数，并使用这些注意力因数来更新每个节点的隐式特征。不同于传统的 GCN，GAT 使用注意力机制来代替图拉普拉斯矩阵来对邻居节点中的特征进行聚合。在此，本文将详细介绍 GAT 层的原理。

在 GAT 中，即将被模型操作的图被定义为 $G=(V,E,A)$ ，其中， V 表示图 G 中的节点的集合， E 表示图 G 中所有边的集合， A 表示图 G 的邻接矩阵。在这之后， v_i 被定义为节点集合 V 中的第 i 个节点。基于上述定义，节点 v_i 在第 l 层的特征向量被进一步表示为 $h_i \in \mathbb{R}^{d(l)}$ ，其中， $d(l)$ 表示节点 v_i 在第 l 层的特征向量的长

度。




图 2.2 图注意力层^[50]

Figure 2.2 Graph Attention Layer^[50]

如图 2.2 所示，节点 v_i 和它的某个邻居节点 v_j 之间的注意力因子如公式(2.12)所示：

$$e_{ij} = a(Wh_i, Wh_j) \quad (2.12)$$

其中， $W \in \mathbb{R}^{d(l+1) \times d(l)}$ 是第 l 层可训练的参数， $a(\cdot)$ 是用来计算节点 v_i 和节点 v_j 之间关联性的函数。需要注意的是， $v_j \in N_{v_i}$ ，其中 N_{v_i} 表示节点 v_i 的邻居节点的集合。关于函数 $a(\cdot)$ 的选择，学者们常常使用一个可训练的前馈神经网络^[50]。因此，节点 v_i 与其邻居节点 v_j 之间的注意力因子可以被表示为：

$$e_{ij} = \sigma(\vec{a}^T [Wh_i \parallel Wh_j]) \quad (2.13)$$

其中， \cdot^T 和 \parallel 分别表示矩阵的转置操作和拼接操作。 $\sigma(\cdot)$ 表示激活函数，在这里，GAT 选用 *LeakyReLU* 作为激活函数。

在上述操作之后，*softmax* 函数被用来对注意力因子进行归一化操作：

$$\alpha_{ij} = \text{softmax}(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{v_k \in N_{v_i}} \exp(e_{ik})} \quad (2.14)$$

通过上述公式，将注意力因子归一化之后，节点 v_i 新的特征向量即可通过加权相加的方式进行计算，具体过程如公式(2.15)所示：

$$h_i' = \sigma \left(\sum_{v_j \in N_{v_i}} \alpha_{ij} W h_j \right) \quad (2.15)$$

其中, h_i' 表示经过注意力操作后, 节点 v_i 新的特征向量。

在空间相关性建模中, 图注意力网络可以对非欧氏的空间数据进行有效的特征提取。基于上述理论与公式, 基于 GAT 的空间特征提取可以被表示为:

$$h_i^l' = \text{graphAtt}_l(h_i^l, h_j^l), v_j \in N_{v_i} \quad (2.16)$$

其中, $\text{graphAtt}_l(\cdot)$ 表示第 l 个 GAT 层, h_i^l 和 h_j^l 分别表示在第 l 层中节点 v_i 和节点 v_j 的特征向量, N_{v_i} 表示节点 v_i 的邻居节点的集合。

此外, 由于在时空预测问题中, 时间维度的建模是必不可少的建模方向。所以, 时空预测中的空间特征需要在时间维度上的各个时间点上分别进行提取。因此, 基于图注意力网络的时空空间特征提取如公式(2.17)所示:

$$h_i^{l,t'} = \text{graphAtt}_l(h_i^{l,t}, h_j^{l,t}), v_j \in N_{v_i}, t \in 0, 1, 2, \dots, T \quad (2.17)$$

其中, T 表示输入到模型中的序列的长度, 即用于预测的过去时间长度。

如上所述, GAT 首先利用注意力机制来计算每一对邻居节点的相关性系数, 以此使每一个节点为其不同的邻居节点分配不同的权重, 以此实现了自适应邻居节点重要性分配, 从而为不同的邻居节点建立了不同的重要性联系。因此, 基于 GAT 的城市空间相关性建模, 可以使每一个区域按照其与不同邻居区域的重要性差别来建立不同的区域对间联系, 这是一种自适应的城市区域空间相关性建模, 同时也是一种自适应空间特征提取方式。

综上所述, 基于 GAT 的城市空间相关性建模解决了传统 GCN 无法为不同邻居区域建立不同重要性关系的问题, 从而实现了一种更加合理、有效的城市空间相关性建模方式。本文将基于 GAT 来为城市空间相关性进行建模, 以此来实现自适应城市空间相关性建模与自适应城市空间特征提取。

2.3.2 基于通勤关系的动态空间图结构

如上文所述, 时空预测方法是一种使用历史序列数据来预测未来时间间隔中数据的方法, 如公式(2.3)所示。因此输入到模型中的数据是一种时空数据, 即包含了空间信息的时间序列数据, 其中, 序列中的每个位置代表了某个时间间隔中的空间信息, 因此, 模型将会在序列中的每个位置上 (即每个时间间隔) 来分别提取空间特征。

在基于图神经网络 (Graph Neural Network, GNN) 的时空预测方法中, 输入到模型中的序列数据是图序列数据, 即序列中的每个位置为表示城市区域空间信息的图结构数据, 如公式(2.4)所示。

现有的基于 GCN 的城市时空预测方法在构建城市图结构时, 是基于区域地理

近邻关系或基于区域功能性关系来建立图中节点（区域）之间边的关系。例如，使用图 2.1 中的城市区域来构建城市区域空间图时，在基于区域地理近邻关系构建的城市空间图中，区域 D 和区域 E 在地理上具有近邻关系，因此节点 D 和节点 E 是邻居节点，两节点之间具有边进行连接；区域 B 和区域 E 在地理上不具有近邻关系，因此节点 B 和节点 E 并不是邻居节点，两节点间不具有边进行连接。在基于区域功能性关系构建的城市空间图中，由于区域 A 和区域 D 都是商业区，具有相同的功能性，因此，节点 A 和节点 D 在图中是邻居节点，两节点间具有边进行连接。

上述基于区域地理近邻关系和区域功能性关系构建的图结构，在城市空间图结构的构建中均取得了良好的效果^[4]，但是，这种城市空间图结构的构建方式存在一个问题，即所构建的图结构不具备时间特定性，即这种空间图结构会在不同的时间间隔中保持一致，这样会导致模型在不同的时间间隔中建立一种静态的区域空间关联性。这种静态的区域空间关联性，在空间特征的提取中具有局限性。例如，在图 2.1 中，区域 A 和区域 B 分别是商业区和住宅区，区域 A 的用车需求量在晚高峰期时会受到区域 B 的较大影响，即在下班的时间段中，会有大量的从区域 A 到区域 B 的用车需求，而在早晨的时候，区域 A 的用车需求量受区域 B 的影响较小。反之，区域 B 的用车需求量在早高峰时会受到区域 A 的较大影响，即在上班的时间段中，会有大量的从区域 B 到区域 A 的用车需求，而在下午或晚上的时候，区域 B 的用车需求量受区域 A 的影响较小。因此，静态的图结构，在建立这种受不同时间间隔影响较大的区域空间关联性时具有局限性，不足以针对不同的时间间隔来建立有效可靠的动态空间关联性。

为了解决这个问题，本文提出了一种基于通勤关系的时间特定性动态空间图结构，以此来建立具有时间特定性的动态区域空间关联性。

具体而言，在构建城市空间图结构时，节点间的连接关系是基于其对应区域间的实时通勤关系来构建的，即根据区域间的通勤关系来建立节点间具有方向性的边来进行连接，以此来构建一种具有时间特定性的动态有向图。例如，在图 2.1 中，区域 A 和区域 B 分别是商业区和住宅区，在时间间隔 t 中，如果具有从区域 A 到区域 B 的用车通勤，但是没有从区域 B 到区域 A 的用车通勤，则在城市空间图中，在时间间隔 t 中具有从节点 A 到节点 B 的有向边，但没有从节点 B 到节点 A 的有向边，则对于节点 A 来说，节点 B 是其邻居节点，但对于节点 B 来说，节点 A 不是其邻居节点。如果在时间间隔 t 中，区域 A 和区域 B 之间不存在用车通勤（双向均不存在），则在时间间隔 t 中，节点 A 和节点 B 之间不存在任何边连接关系，即节点 A 不是节点 B 的邻居节点，节点 B 也不是节点 A 的邻居节点。通过这种方式，节点实现了动态的邻居节点选择，因此城市空间图由静态的图结构变为了具

有时间特定性的动态图结构。

在上述方法的基础上，城市空间图结构被定义为具有时间特定性的有向图结构 $G' = (V, E', A')$ 。其中， G' 表示在时间间隔 t 中的城市空间图。 V 表示节点的集合，节点集合 V 中的每个节点 v 表示城市中一个单独的区域。 E' 表示在时间间隔 t 中，图 G' 的边集合。 A' 表示在时间间隔 t 中，图 G' 的邻接矩阵。如上文所述， G' ， E' 和 A' 是基于通勤关系构建而成的，具有时间特定性。因此，公式(2.4)中的基于图神经网络的共享出行用车需求预测任务变为：

$$X^{t+1} = \mathcal{F}(\{(X^{t-L+1}, G^{t-L+1}), \dots, (X^{t-1}, G^{t-1}), (X^t, G^t)\}) \quad (2.18)$$

2.4 数据的时空预处理

2.4.1 原始数据信息

本文中的所使用的共享出行数据来自于“滴滴-盖亚开放数据计划”平台^①。数据集包含了从 2017 年 5 月 1 日-10 月 31 日海口市每天的订单数据，每条订单包含了起终点经纬度、订单开始时间、订单结束时间等属性。其中所有涉及个人信息的数据都经过了匿名化处理。数据的统计结果信息和原始字段信息分别如表 2.1 和表 2.2 所示：

表 2.1 数据集统计结果

Table 2.1 Statistical results of the dataset

统计信息	统计结果
订单总量	12,185,427
经纬度范围内的订单量	10,500,367
订单最大经度值	110.3860
订单最大纬度值	20.0814
订单最小经度值	110.2807
订单最小纬度值	19.9820

^① <https://gaia.didichuxing.com>

表 2.2 数据集原始字段信息

Table 2.2 Original field information of the dataset

字段 ID	字段名	字段描述
order_id	订单 ID	订单的 ID 号
product_id	产品类型 ID	订单所使用的产品的 ID 号: 1 专车 2 企业专车 3 快车 4 企业快车
city_id	城市 ID	订单所在城市的 ID 号, 本数据集中为海口市
district_id	城市区号	订单所在的城市的区号 ID
county_id	区县 ID	订单所在的区县的 ID 号
type	订单时效类型	订单的时效类型: 0 实时用车 1 预约用车
combo_type	订单用车类型	订单的用车类型: 1 包车 4 拼车
traffic_type	交通类型	订单的交通类型: 1 企业时租 2 企业接机套餐 3 企业送机套餐 4 拼车 5 接机 6 送机
passenger_count	乘车人数	订单中, 参与用车的用户人数
driver_product_id	司机子产品线	订单指派的司机所属的产品线
start_dest_distance	行车距离	订单中起点与终点间的预估距离
arrive_time	到达时间	订单结束时间
departure_time	出发时间	订单开始时间
pre_total_fee	预估价格	订单预计用户所需费用
normal_time	订单时长	订单实际花费时间
starting_lng	起点的经度	订单中起点的经度
starting_lat	起点的维度	订单中起点的纬度
dest_lng	终点的经度	订单中目的地的经度
dest_lat	终点的维度	订单中目的地的纬度

2.4.2 数据的时间预处理

数据的时间预处理旨在将原始订单数据整合成时间序列数据。如上文所述, 原始数据集包含了从 2017 年 5 月 1 日-10 月 31 日共 184 天的订单数据。在本文中, 单个时间间隔设置为 1 个小时, 因此原始数据集中共包含 4416 个时间间隔 (时间间隔 id 为 0 至 4415)。

基于上述规则, 本文将每条订单的开始时间视为该条订单所处的时间间隔,

并对原始数据中每条订单的开始时间进行处理，计算每条订单所对应的时间间隔 id 。

2.4.3 数据的空间预处理

在将数据进行了时间预处理之后，本文接下来将对数据进行空间预处理。

首先，对处于时间间隔 t ($0 \leq t \leq 4415$) 中的订单数据，根据经纬度来对每一条数据进行区域划分。具体而言，在数据集中，对经纬度范围内的城市区域进行分割，从而得到 11×11 的矩形网格，其中的每一个网格代表一个区域。每个区域的大小约为 $1km \times 1km$ 。

然后，对于时间间隔 t ，计算各个区域作为起始区域时的订单总数，即各个区域在时间间隔 t 中的需求量。

最后，对整个城市进行建模。具体而言，将每个区域都作为图中的一个节点，单个区域在 t 时刻的需求量即为该节点的特征值，以此来建立在时间间隔 t 中的城市区域图。

如上文所述，本文采取了一种基于通勤关系的动态空间图结构，因此，城市结构图中边的连接是基于通勤关系的，即在时间间隔 t 中，若从区域 A 到区域 B 的订单数不为 0，则认为在时间间隔 t 中，从区域 A 到区域 B 具有实际的通勤关系，从而在时间间隔 t 中的城市结构图 $G' = (V, E', A')$ 中，具有从节点 A 到节点 B 的边连接。

此外，本文同样构建了基于区域地理近邻关系、基于区域功能性关系和基于区域路网连接关系的城市区域图结构，为本文所对比的基准模型使用，以此来证明本文所提出的基于通勤关系的动态空间图结构的合理性和有效性。

2.5 本章小结

本章节对共享出行中的用车需求预测问题进行了详细的定义和公式化描述，然后对现有的时空特征提取方法进行了详细的描述，并介绍了本文中两个主要的创新点——基于图注意力网络的自适应空间相关性和基于通勤关系的时间特定性动态空间图结构。此外，本章节还对本文所用到的共享出行数据集的原始字段信息进行了描述，并介绍了本文中对数据集的时间预处理和空间预处理方法。

3 基于时空动态图注意力网络的共享出行用车需求预测模型

3.1 模型整体结构

图 3.1 展示了本文所提出的时空动态图注意力网络（Spatial-Temporal Dynamic Graph Attention Network, STDGAT）的整体结构。STDGAT 由空间模块、时间模块和输出预测层三个部分组成。其中，空间模块使用了一个 GAT Block 来提取空间特征，并将提取到的空间特征序列传入到时间模块中。时间模块使用了长短期记忆网络（Long Short-Term Memory, LSTM）^[58]来对空间模块输出的空间特征序列进行时间特征的提取，并将提取到的联合时空特征输出到输出预测层中。最后，输出预测层将联合时空特征映射成真实的需求向量，并将该需求向量作为模型最终的输出结果。接下来，本文将对模型中各个模块的内部结构进行详细阐述。

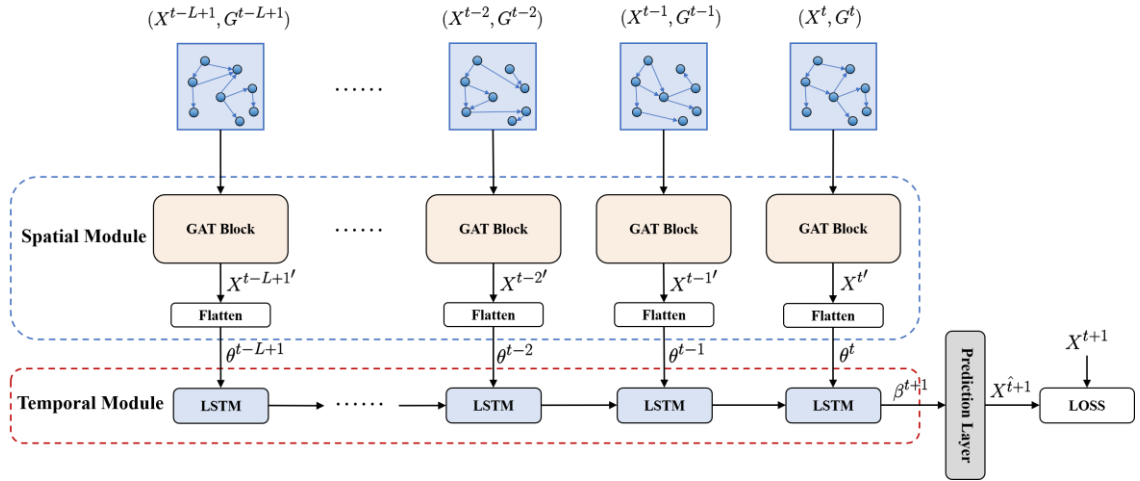


图 3.1 模型整体结构

Figure 3.1 The Architecture of Proposed Model

3.2 空间模块

空间模块用于在每个时间间隔中，提取全局的空间特征。空间模块包含一个由多个 GAT 层组成的 GAT Block。GAT Block 的内部结构如图 3.2 所示。




图 3.2 GAT Block 内部结构

Figure 3.2 Internal Structure of GAT Block

需要注意的是，GAT 层的参数在不同时间间隔中是共享的，因此，GAT Block 在输入序列中的参数也是共享的。所以 GAT Block 的参数量不会随着输入序列的长度的变化而变化，即无论输入序列的长度为多少，空间模块的参数量均保持不变。

在本文中，GAT Block 中的每个 GAT 层被表示为：

$$X'_{l+1} = f_l(X'_l) \quad (3.1)$$

其中 $X'_l \in \mathbb{R}^{N \times d(l)}$ 表示在时间间隔 t 中，第 l 个 GAT 层的输入。 $f_l(\cdot)$ 表示第 l 个图注意力层的操作。 N 和 $d(l)$ 分别表示城市的区域总数和第 l 层中每个节点的特征向量长度。因此，时间间隔 t 中的需求 X' 在经过所有 GAT 层之后，GAT Block 的输出可以表示为：

$$X'^t = GATBlock(X^t) \quad (3.2)$$

其中 $X'^t \in \mathbb{R}^{N \times d}$ 为在时间间隔 t 中从 GAT Block 输出的空间特征， d 表示在经过了 GAT Block 之后每个节点的特征向量长度， $GATBlock(\cdot)$ 表示 GAT Block 的整体操作。

在经过了图注意力操作之后，从 GAT Block 输出的特征矩阵 X'^t 被展开得到特征向量 $\theta^t \in \mathbb{R}^{Nd}$ 。最后，长度为 L 的需求序列经过空间模块后，输出的空间特征序列 $S_{t+1} \in \mathbb{R}^{L \times Nd}$ 表示为：

$$S_{t+1} = [\theta^n \mid n = t, t-1, t-2, \dots, t-L+1] \quad (3.3)$$

3.3 时间模块

由于需求序列数据是一种时间序列数据，因此，在其建模过程中，时间依赖性建模是必不可少的因素。在时间依赖性建模中，循环神经网络（Recurrent Neural Networks, RNN）已被证明可以取得良好的效果^[41]，在 RNN 的基础上，长短期记忆（LSTM）的引入克服了传统的 RNN 难以学习长期依赖性关系的缺点^{[58][59][60]}。此外，在已有的关于时空预测的文献中表明，LSTM 在处理这种时序数据时具有优异的表现^{[4][10][32]}。因此，本文在 STDGAT 的时间模块中，使用了 LSTM 来对需求序列数据的时间依赖性进行建模。传统 RNN 和 LSTM 的内部结构对比如图 3.3 和图 3.4 所示。

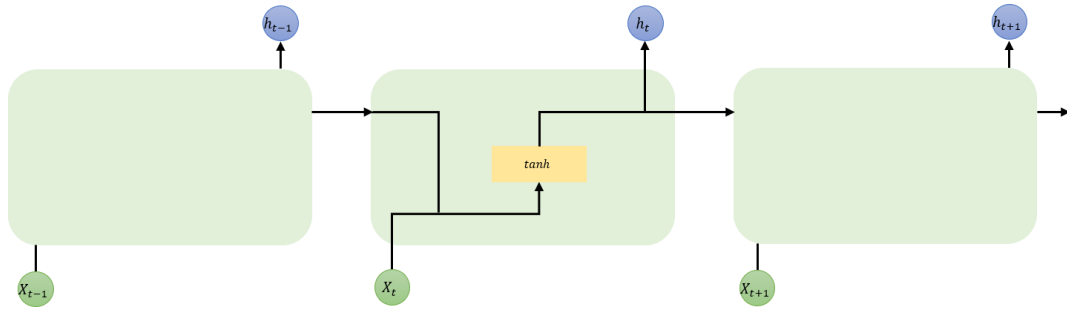


图 3.3 传统 RNN 内部结构

Figure 3.3 Internal Structure of Traditional RNN




图 3.4 LSTM 内部结构

Figure 3.4 Internal Structure of LSTM

在 RNN 的基础上，LSTM 引入了一个记忆单元 c_t 来累积序列中之前时刻的信息。具体而言，在 t 时刻，给定输入 x_t ，LSTM 使用一个输入门 i_t 和一个遗忘门 f_t 来更新记忆单元 c_t ，并且使用一个输出门 o_t 来控制隐藏状态 h_t 。其表达式如公式(3.4)所示：

$$\begin{aligned}
i_t &= \sigma(W_{ii}x_t + b_{ii} + W_{hi}h_{t-1} + b_{hi}) \\
f_t &= \sigma(W_{if}x_t + b_{if} + W_{hf}h_{t-1} + b_{hf}) \\
g_t &= \tanh(W_{ig}x_t + b_{ig} + W_{hg}h_{t-1} + b_{hg}) \\
o_t &= \sigma^*(W_{io}x_t + b_{io} + W_{ho}h_{t-1} + b_{ho}) \\
c_t &= f_t \circ c_{t-1} + i_t \circ g_t \\
h_t &= o_t \circ \tanh(c_t)
\end{aligned} \tag{3.4}$$

其中， σ 表示 sigmoid 激活函数， \circ 表示 Hadamard 乘积， $W_{pq}, b_{pq} (p \in (i, h), q \in (i, f, g, o))$ 为 LSTM 的可训练参数， c_t 和 h_t 分别表示在 t 时刻的记忆单元状态和隐藏状态。

在 STDGAT 的时间模块中，LSTM 将空间模块输出的空间特征序列 S_{t+1} 作为输入，然后输出时空联合特征向量 $\beta^{t+1} \in \mathbb{R}^k$ ，其中 k 表示 LSTM 中隐藏单元的数量。

3.4 输出预测层

在经过了上述时间模块和空间模块后，STDGAT 已经获得了原始序列的联合时空特征向量 β^{t+1} 。接下来需要使用一个输出预测层来将 β^{t+1} 映射成具体的需求值向量。在本文中，STDGAT 在最后使用了一个具有 N 个神经元的可训练全连接层作为最后的输出预测层 (N 代表城市中的区域总数)。输出预测层的公式可表示为：

$$\hat{X}^{t+1} = f(W_{FC}\beta^{t+1} + b_{FC}) \tag{3.5}$$

其中， \hat{X}^{t+1} 表示最终的预测结果， $W_{FC} \in \mathbb{R}^{k \times N}$ 和 $b_{FC} \in \mathbb{R}^N$ 分别表示输出预测层的权重和偏置， $f(\cdot)$ 表示激活函数。

3.5 本章小结

本章节首先对 STDGAT 的模型整体结构进行了简要介绍，然后分别对空间模块、时间模块和输出预测层三个部分进行了详细的阐述。

4 共享出行用车需求预测实验结果与分析

4.1 实验细节设置

4.1.1 模型参数设置

本小节将详细介绍 STDGAT 在训练过程中具体的参数设置。在 STDGAT 中, 输入序列长度 L 被设置为 5。在空间模块中, GAT Block 中的 GAT 层的数量为 3, 每一层包含 32 个隐藏单元。在时间模块中, LSTM 具有一个含有 512 个神经元的隐藏层。GAT 层中的激活函数为 *LeakyReLU*, 在输出预测层中的激活函数为 *ReLU*。本文通过 Adam^[61] 优化器来对损失函数进行优化。在训练过程中, 学习率和权重衰减值分别为 $1e-3$ 和 $5e-5$ 。模型的代码基于深度学习库 Pytorch^[62] 进行编写, 并在两块 NVIDIA 1080Ti GPU 上进行训练, 最大训练轮数为 200。

4.1.2 实验数据设置

本小节将详细阐述实验过程中, 数据的具体使用情况。本文中所使用来自于滴滴出行的共享出行数据集。数据集包含了海口市从 2017 年 5 月 1 日至 2017 年 10 月 31 日的共享出行订单数据。数据集中包含了 121 个区域, 每个区域的大小约为 $1km \times 1km$ 。在本文中, 时间间隔被设置为 1 小时。数据集中的总订单数和总时间间隔数分别为 12,185,427 和 4,416。

在本文的实验部分, 从 2017 年 5 月 1 日至 2017 年 9 月 30 日的数据被作为训练集来对模型进行训练, 剩余的数据 (2017 年 10 月 1 日至 2017 年 10 月 31 日) 被作为测试集来对模型进行测试。在训练集中, 80% 的数据被用来做训练, 剩余 20% 被作为验证集来使用。

4.1.3 损失函数

在训练阶段, STDGAT 使用均方误差 (Mean Square Error, MSE) 损失作为损失函数, 并通过最小化 MSE 来训练模型。MSE 是回归问题中常用的损失函数之一, 其公式可表示为:

$$\mathcal{L}(\Theta) = \frac{1}{z} \sum_i (y_i - \hat{y}_i)^2 \quad (4.1)$$

其中 Θ 表示模型的所有可训练参数, y_i 和 \hat{y}_i 分别代表真实值和预测值, z 表示样本的总数。

4.1.4 性能度量指标

本文采用了三种适用于需求预测任务的评价指标, 分别为均方根误差 (Rooted Mean Square Error, RMSE), 平均百分比误差 (Mean Average Percentage Error, MAPE) 和平均绝对误差 (Mean Absolute Error, MAE)。如公式(4.2)-(4.4)所示:

$$RMSE = \sqrt{\frac{1}{z} \sum_{i=1}^z (y_i - \hat{y}_i)^2} \quad (4.2)$$

$$MAPE = \frac{1}{z} \sum_{i=1}^z \frac{|y_i - \hat{y}_i|}{y_i} \quad (4.3)$$

$$MAE = \frac{1}{z} \sum_{i=1}^z |y_i - \hat{y}_i| \quad (4.4)$$

其中 y_i 和 \hat{y}_i 分别表示真实值和预测值, z 表示所有样本的总数。

4.2 基准方法

为了验证 STDGAT 的性能, 本文选取了如下模型作为基准模型, 并使用这些基准模型来与 STDGAT 进行比较。

- 历史平均 (Historical average, HA) : HA 通过对过去连续时间间隔内给定区域的历史需求序列进行平均, 以此作为所预测的结果。
- 自回归移动平均 (Autoregressive integrated moving average, ARIMA) : ARIMA 是一种常见的用于时间序列预测的模型。
- Lasso 回归 (Lasso regression, Lasso) : Lasso 是一种使用 L_1 正则化的线性回归模型。
- 岭回归 (Ridge regression, Ridge) : Ridge 是一种使用 L_2 正则化的线性回归模型。
- XGBoost^[63]: XGBoost 是一种基于 boosting 树的方法, 被广泛应用于多种数据挖掘任务中。
- 多层感知机 (Multiple layer perception, MLP) : MLP 是一个由多个全连接层组成的神经网络模型, 在本文中, MLP 由 4 个隐藏层组成, 分别包含 128, 128, 64, 64 个神经元。
- DMVST-Net^[10]: DMVST-Net 是一个基于 CNN 和 LSTM 的深度学习模型, 用于出租车需求预测。该模型还包含了一个额外的图嵌入模块来捕获区域间相似的需求模式。
- STGCN^[39]: STGCN 是一个基于 GCN 的交通预测模型。该模型使用 GCN 来提取空间特征, 并使用了一维卷积来对时间依赖性进行建模。
- ST-MGCN^[4]: ST-MGCN 是一个用于网约车需求预测的前沿方法。其使用了区域地理近邻关系、区域功能相似性和区域路网连通性构建了三种不同

的空间图结构, 并使用 GCN 来分别提取其空间特征。此外, ST-MGCN 还提出了语义门控循环神经网络 (Contextual Gated Recurrent Neural Network, CGRNN) 来捕获时间依赖性特征。

4.3 与基准方法实验结果的对比与分析

图 4.1 和表 4.1 展示了基准模型和 STDGAT 的实验结果对比。从表中可以看出, STDGAT 在三个评价指标上均达到了最好的效果。HA 和 ARIMA 的表现最差, 这是由于这两个模型只能依靠历史需求数据值来进行预测, 并没有考虑任何相关特征。由于考虑了序列中更多的上下文信息, 线性回归模型 (Lasso 和 Ridge) 的表现要优于 HA 和 ARIMA。但是, 线性回归模型无法提取更多的特征来进行预测, 因此它们的预测误差依然较大。XGBoost 和 MLP 进一步对输入序列进行了变换, 并提取了序列中的隐藏信息, 因此, 它们的表现相比于上述四种方法, 得到了进一步的提升。但是, 它们依然没能在空间维度或时间维度上对数据进行建模。

三个深度学习方法 (DMVST-Net、STGCN、ST-MGCN) 进一步考虑了时空依赖性, 因此它们达到了较为理想的效果。与这三种方法相比, 由于考虑了不同邻居区域间的自适应空间相关性和具有时间特定性的动态空间图结构, STDGAT 的表现更加优异。具体而言, DMVST-Net 在提取全局空间特征时, 仅仅将一个固定的静态图嵌入到一个向量中, 这种方式对于提取自适应和动态空间相关性具有局限性。STGCN 和 ST-MGCN 对区域间的非欧氏空间相关性进行了建模, 这是一种合理有效的方式。但是, 由于这两种方法在对非欧氏空间相关性进行建模时, 使用的是传统的 GCN 模型, 因此他们只能让每个区域为不同的邻居区域分配相同的重要性。此外, STGCN 与 ST-MGCN 并没有考虑具有时间特定性的动态空间图结构, 因此, 它们的效果相比于 STDGAT 要略显逊色。




图 4.1 与基准模型的对比

Figure 4.1 Comparison with Different Baselines

表 4.1 与基准模型的对比

Table 4.1 Comparison with Different Baselines			
方法	RMSE	MAPE	MAE
HA	24.1629	0.4710	13.5835
ARIMA	22.5440	0.3769	12.4762
Lasso	19.5851	0.3080	11.3082
Ridge	19.5968	0.3069	11.3178
XGBoost	11.3143	0.2572	6.5740
MLP	10.4753	0.2367	5.6806
DMVST-Net	8.8695	0.1914	4.5365
STGCN	8.6153	0.1909	4.5579
ST-MGCN	8.5190	0.1827	4.4022
STDGAT	7.8811	0.1744	4.0881

4.4 不同时间段上的实验结果的对比与分析

4.4.1 工作日与周末的实验结果对比

表 4.2、表 4.3 以及图 4.2 展示了 STDGAT 和基准模型分别在工作日和周末的表现。STDGAT 无论是在工作日还是在周末均具有最佳表现。

此外，在工作日和周末的实验结果比较中具有一个现象，那就是所有的方法在周末的表现均比在工作日要差。其中的原因在 Yao 等人^[10]的工作中得到了相关解释，即周末的需求模式和工作日的需求模式相比，具有更多的不规则性。规则的需求模式更加有利于模型去学习，因此在工作日中，模型的表现要更加优于在周日的表现。




图 4.2 模型在工作日和周末的表现

Figure 4.2 Performance on Weekdays and Weekend

表 4.2 各方法在工作日的实验结果

Table 4.2 Experiment results of Different Methods on Weekdays			
方法	RMSE	MAPE	MAE
HA	23.3195	0.4527	12.8880
ARIMA	21.9180	0.3650	12.0388
Lasso	18.4825	0.2854	10.6484
Ridge	18.5012	0.2844	10.6614
XGBoost	10.7005	0.2563	6.3813
MLP	9.8009	0.2362	5.5024
DMVST-Net	7.9490	0.1882	4.2704
STGCN	7.8303	0.1894	4.3235
ST-MGCN	7.7373	0.1815	4.1857
STDGAT	7.1174	0.1728	3.8622

表 4.3 各方法在周末的实验结果

Table 4.3 Experiment results of Different Methods on Weekend			
方法	RMSE	MAPE	MAE
HA	27.5198	0.5132	15.2835
ARIMA	24.0058	0.4044	13.5453
Lasso	22.0495	0.3600	12.9211
Ridge	22.0470	0.3586	12.9223
XGBoost	12.6902	0.2593	7.0450
MLP	11.9649	0.2381	6.1162
DMVST-Net	10.7942	0.1987	5.1870
STGCN	10.2849	0.1944	5.1312
ST-MGCN	10.1803	0.1855	4.9313
STDGAT	9.4927	0.1780	4.6402

4.4.2 一周中不同天上的实验结果对比

本小节比较了 STDGAT 与基准模型在一周中的不同天的实验结果。

表 4.4 至表 4.10 和图 4.3 分别展示了 STDGAT 和基准方法从周一到周日的表现。如表中和图中所示，与基准模型相比，STDGAT 在一周的不同天中均保持着

最佳的预测效果。这意味着 STDGAT 具有很好的鲁棒性与可靠性。




图 4.3 模型在不同天的表现

Figure 4.3 Performance on Different Days

表 4.4 各方法在周一的实验结果

Table 4.4 Experiment results of Different Methods on Monday			
方法	RMSE	MAPE	MAE
HA	24.7669	0.5155	14.0034
ARIMA	21.6222	0.3609	11.9304
Lasso	18.1516	0.2816	10.5401
Ridge	18.1736	0.2806	10.5542
XGBoost	10.3998	0.2509	6.1927
MLP	9.5173	0.2286	5.3021
DMVST-Net	7.8849	0.1809	4.3304
STGCN	7.4303	0.1819	4.1881
ST-MGCN	7.4546	0.1804	4.1026
STDGAT	6.8224	0.1715	3.7963

表 4.5 各方法在周二的实验结果

Table 4.5 Experiment results of Different Methods on Tuesday			
方法	RMSE	MAPE	MAE
HA	22.8943	0.4579	12.9131
ARIMA	21.8749	0.3668	12.1031
Lasso	18.6675	0.2919	10.8304
Ridge	18.6859	0.2908	10.8432
XGBoost	11.0612	0.2638	6.5804
MLP	10.1681	0.2442	5.7175
DMVST-Net	8.1526	0.1967	4.3420
STGCN	8.2977	0.1969	4.4852
ST-MGCN	8.0678	0.1876	4.3517
STDGAT	7.9177	0.1848	4.1599

表 4.6 各方法在周三的实验结果

Table 4.6 Experiment results of Different Methods on Wednesday			
方法	RMSE	MAPE	MAE
HA	19.7057	0.4014	10.9718
ARIMA	21.1481	0.3661	11.5270
Lasso	17.0944	0.2723	9.8945
Ridge	17.1235	0.2717	9.9162
XGBoost	9.5562	0.2539	5.9455
MLP	8.7211	0.2340	5.1023
DMVST-Net	7.4064	0.1961	4.1670
STGCN	6.7179	0.1860	4.0081
ST-MGCN	6.6134	0.1791	3.8641
STDGAT	6.2493	0.1700	3.5673

表 4.7 各方法在周四的实验结果

Table 4.7 Experiment results of Different Methods on Thursday			
方法	RMSE	MAPE	MAE
HA	23.6389	0.4357	12.5972
ARIMA	21.7777	0.3580	11.7639
Lasso	18.0663	0.2735	10.2760
Ridge	18.0882	0.2726	10.2915
XGBoost	10.4234	0.2516	6.2625
MLP	9.4370	0.2307	5.3751
DMVST-Net	7.5066	0.1786	3.9336
STGCN	7.4324	0.1845	4.1293
ST-MGCN	7.5789	0.1742	4.0042
STDGAT	6.8034	0.1664	3.6755

表 4.8 各方法在周五的实验结果

Table 4.8 Experiment results of Different Methods on Friday			
方法	RMSE	MAPE	MAE
HA	24.9372	0.4356	13.6693
ARIMA	23.1980	0.3732	12.8805
Lasso	20.3163	0.3054	11.6828
Ridge	20.3205	0.3040	11.6831
XGBoost	11.9019	0.2602	6.9223
MLP	10.9881	0.2424	6.0114
DMVST-Net	8.6905	0.1885	4.5462
STGCN	9.0433	0.1969	4.8000
ST-MGCN	8.7899	0.1846	4.5853
STDGAT	7.5321	0.16845	4.0541

表 4.9 各方法在周六的实验结果

Table 4.9 Experiment results of Different Methods on Saturday			
方法	RMSE	MAPE	MAE
HA	27.3312	0.4840	15.2367
ARIMA	24.4184	0.4129	14.0465
Lasso	22.7815	0.3689	13.4498
Ridge	22.7724	0.3673	13.4432
XGBoost	13.1987	0.2576	7.2654
MLP	12.5531	0.2378	6.3566
DMVST-Net	10.4770	0.1899	5.0890
STGCN	10.0517	0.1856	5.0852
ST-MGCN	10.0487	0.1814	4.9665
STDGAT	9.6189	0.1731	4.6772

表 4.10 各方法在周日的实验结果

方法	RMSE	MAPE	MAE
HA	27.6697	0.5384	15.3210
ARIMA	23.6705	0.3971	13.1443
Lasso	21.4459	0.3522	12.4981
Ridge	21.4491	0.3510	12.5056
XGBoost	12.2684	0.2608	6.8692
MLP	11.4727	0.2383	5.9239
DMVST-Net	11.0414	0.2062	5.2655
STGCN	10.4677	0.2020	5.1680
ST-MGCN	10.2843	0.1891	4.9031
STDGAT	9.3905	0.1823	4.6106

4.5 不同模块上的实验结果

如上文所述，STDGAT 有两个不同的特征提取模块（空间模块和时间模块）。为了探索这两个模块对预测结果的影响，本文分别在空间模块和时间模块上进行了实验，并将实验结果与完整的 STDGAT 进行了对比。

4.5.1 空间模块上的实验结果

为了验证 STDGAT 中时间模块的有效性，本小节使用如下模型进行了实验：

- 空间模块 + 输出预测层（Spatial module + Prediction layer）：该模型由 STDGAT 的空间模块和输出预测层组成。该模型仅提取空间特征来进行预测，以此来探讨在缺乏时间特征提取时模型的性能。
- STDGAT：本文所提出的完整模型，同时包含了空间模块、时间模块和输出预测层。

如表 4.11 所示，Spatial module + Prediction layer 的效果与完整的 STDGAT 相比有大幅度下降。这是由于 Spatial module + Prediction layer 只提取了空间特征来进行预测，并没有考虑对时间依赖性的建模。如上文所述，时间依赖性建模在时空预测中是至关重要的，因此，缺少了时间依赖性建模，模型的性能会大幅度下降。由此也可以看出，STDGAT 的时间模块的重要性与合理性。

表 4.11 STDGAT 与空间模块的实验对比

Table 4.11 Comparison with Spatial Module

方法	RMSE	MAPE	MAE
Spatial module + Prediction layer	9.6273	0.2143	5.2131
STDGAT	7.8811	0.1744	4.0881

4.5.2 时间模块上的实验结果

为了验证 STDGAT 中空间模块的有效性，本小节使用如下模型进行了实验：

- 时间模块 + 输出预测层（Temporal module + Prediction layer）：该模型由 STDGAT 的时间模块和输出预测层组成。该模型仅提取时间特征来进行预测，以此来探讨在缺乏空间特征提取时，模型的性能。
- STDGAT：本文所提出的完整模型。

如表 4.12 所示，Temporal module + Prediction layer 的效果与完整的 STDGAT 相比大幅度下降。这是由于 Temporal module + Prediction layer 只提取了时间特征来进行预测，并没有考虑对空间关联性的建模。空间关联性建模在时空预测中同样是不可缺少的，因此，在缺少了空间关联性建模时，模型的性能会大幅度下降。由此也可以看出，STDGAT 的空间模块的重要性与合理性。

表 4.12 STDGAT 与时间模块的实验对比

Table 4.12 Comparison with Temporal Module

方法	RMSE	MAPE	MAE
Temporal module + Prediction layer	9.3151	0.1946	4.5964
STDGAT	7.8811	0.1744	4.0881

4.6 动态图结构对实验结果的影响

上述实验证明了 STDGAT 在共享出行需求预测任务中达到了优异的效果，并且验证了不同特征提取模块的合理性和有效性。但是，一个重要的因素还没有得到验证，即基于通勤关系的时间特定性动态空间图结构。作为本文的核心贡献之一，本文接下来将对其进行验证。因此，本文构建了如下变体模型作为对比，以此来验证基于通勤关系的时间特定性动态空间图结构的有效性：

STDGAT-fixed：该模型是 STDGAT 的变体，在提取空间特征时，该模型使用了一种在不同时间间隔中所固定的静态空间图结构，即基于区域地理邻接关系所构建的城市空间图结构，以此代替 STDGAT 中基于通勤关系的时间特定性动态空

间图结构。

表 4.13 STDGAT 与变体模型的对比

Table 4.13 Comparison with Variants of STDGAT

方法	RMSE	MAPE	MAE
STDGAT-fixed	8.2334	0.1788	4.1917
STDGAT	7.8811	0.1744	4.0881

STDGAT-fixed 与 STDGAT 的实验结果对比如表 4.13 所示。其中，STDGAT-fixed 在 RMSE、MAPE 和 MAE 三个评价指标上分别达到了 8.2334、0.1788 和 4.1917。STDGAT 的 RMSE、MAPE 和 MAE 分别为 7.8811、0.1744 和 4.0881。由此可以看出，STDGAT 的三个评价指标上的表现均优于 STDGAT-fixed，这意味着本文所提出的基于通勤关系的时间特定性空间图结构在共享出行需求预测任务中，具有比传统的基于区域真实地理邻接关系的图结构更加优异的表现。这也证明了在序列图的学习任务中，相比于静态的空间图结构，动态空间图结构是一种更加可行有效的图表示学习方式。

4.7 输入序列长度与 GAT 层数对实验结果的影响

本小节将分别探讨输入到模型中的序列长度与 GAT 层数对预测结果准确性的影响。

4.7.1 序列长度对实验结果的影响

图 4.4 展示了输入序列长度对预测结果的影响。如图中所示，当输入序列长度为 5 时，模型达到最佳性能。当输入序列长度小于 5 时，预测误差随着序列长度的增加而减小，这意味着随着序列长度的增加，模型可以学习到更长的时间依赖性信息，这些信息有助于对结果的预测。但是当输入序列长度大于 5 时，模型的效果会有略微的下降，并伴随着一些波动。造成这种现象的一个潜在原因是，随着输入序列长度的不断增加，输入到模型中的信息量呈线性增长，因此模型需要将更多的信息与梯度计算过程联系起来，并会造成一定程度上的信息丢失，因此训练过程会变得更加困难。

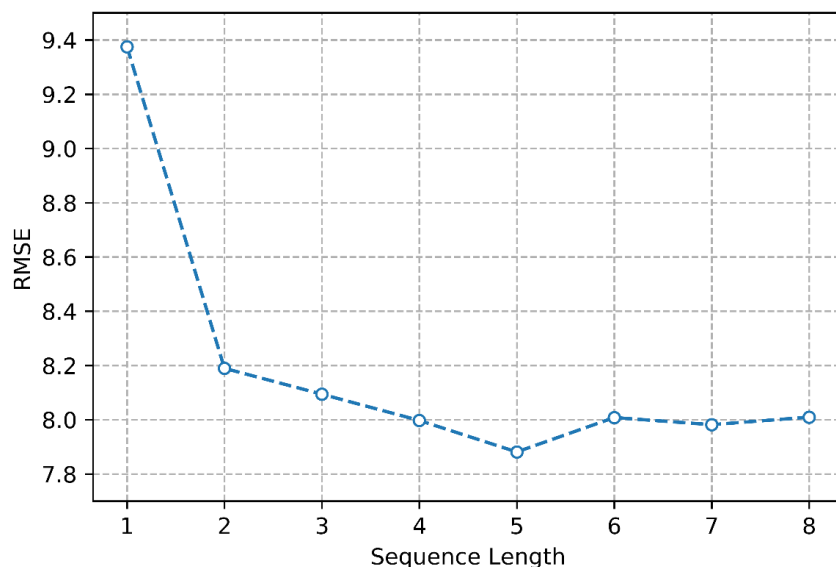


图 4.4 不同输入序列长度的实验结果 (RMSE)

Figure 4.4 RMSE of Different Sequence Length

4.7.2 GAT 层数对实验结果的影响

图 4.5 展示了空间模块中 GAT Block 中的 GAT 层数对实验结果的影响。从图中可以看出,随着 GAT 层数由 0 增加到 5, RMSE 值逐渐降低。这意味着,随着 GAT 层数的增加,模型的效果变得更好。这种现象可以由一个空间特征提取中的事实来解释,即随着层数的加深,原始的特征将进一步和其邻居特征进行聚合,这将使较深的层具有更大的感受野。并且,更大的感受野可以捕获更多的空间关联性。因此,随着层数的加深,模型可以学习更多的空间信息来提高其性能。

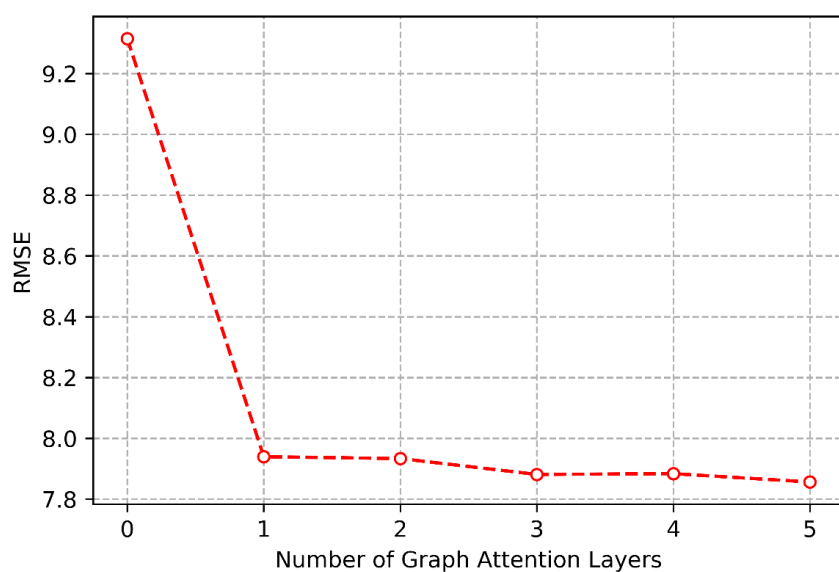


图 4.5 不同 GAT 层数的实验结果 (RMSE)

Figure 4.5 RMSE of Different Number of Graph Attention Layer

4.8 时间消耗和损失值变化

本小节将分析模型在训练阶段的损失变化和时间消耗。

4.8.1 模型训练和验证阶段的损失值变化

为了更好的了解模型在训练和验证阶段的进程，本文分别记录了模型在训练和验证阶段的损失值的变化。




图 4.6 训练和验证阶段的 MSE 损失值变化

Figure 4.6 MSE loss of training and validation with respect to epochs

图 4.6 展示训练和验证阶段的损失曲线。由图中可见，随着训练回合数的增加，模型在训练集和验证集上的损失值均平滑的降低，并且，随着训练损失的降低，验证损失也相应的降低。这些信息表明了模型训练过程的有效性以及模型良好的泛化能力。

4.8.2 模型训练和验证阶段的时间损耗

为了观察 STDGAT 在训练和验证阶段的时间消耗情况，本文在这两个阶段对其时间消耗进行了记录。

如图 4.7 所示，训练和验证的时间随着训练回合数的增加呈线性增长。对于训练阶段来说，每个回合消耗大约 55 秒，训练 200 个回合共消耗了约 3 个小时。对于验证阶段来说，每个回合消耗约 14 秒，200 个回合共消耗了约 45 分钟。




图 4.7 训练和验证阶段时间消耗

Figure 4.7 Time consumption of training and validation with respect to training epochs

4.9 本章小结

本章节对实验阶段的模型参数、实验数据、损失函数、性能度量指标等细节设置和基准模型的设置进行了阐述，并对实验内容和实验结果进行了详细的描述和分析，最后，对模型训练和验证阶段的时间消耗和损失值变化进行了记录和分析。实验结果表明，STDGAT 的效果优于所对比的基准模型，并且 STDGAT 的各个组成模块均起到了重要的作用，此外实验结果还表明了 STDGAT 具有良好的鲁棒性与合理的训练时间和损失值变化趋势。

5 共享出行用车需求预测系统原型

5.1 需求分析

交通是城市日常运行的骨架结构，是城市建设中最基础、最重要的部分之一。作为交通的重要组成部分，出行在人们的生活与城市的发展中扮演着不可或缺的角色。随着移动互联网和共享经济的发展，共享出行作为一种新型的出行服务，在出行服务市场、智能交通和车联网系统中占据着越来越重要的地位，为人们的生活提供了前所未有的便利性。不同于传统的出行服务，共享出行主要以共享和合乘作为车辆使用模式，并借助互联网平台，以网约车、共享汽车、共享单车等方式来为用户提供共享性的车辆资源。

随着共享出行的飞速发展，一些影响平台运营的低效问题开始逐渐浮现出来。例如，用户等待时间过长、空载车辆较多等。这是由车辆在城市中的分布往往是与用户的需求不匹配造成的。具体而言，在用户需求量较多的区域，车辆的供应往往是不足的，但在一些用户需求量较少的区域，却有许多的空载车辆。这样既造成了资源的浪费、平台利润的下降，又降低了用户的体验。

为了提高平台资源的利用率，同时提高用户体验，一个准确高效的用户用车需求预测系统的开发对于共享出行平台来说是至关重要的。因此，本文基于所提出的 STDGAT 模型，设计了一个共享出行用车需求预测系统原型——STDGAT 用车需求预测系统，以此来在实际应用中提供准确可靠的共享出行用车需求预测。

STDGAT 用车需求预测系统使用 STDGAT 算法来作为需求预测算法，并使用预训练好的模型，在长度为 5 小时的时间滑动窗口上来实时的预测下一小时的全局用车需求量。

STDGAT 用车需求预测系统主要包含三个模块，分别为管理员登录模块、昨日全国需求概况模块和区域级实时用车需求模块。管理员登录模块用于对管理员的身份验证，并赋予管理员登录权限。昨日全国需求概况模块用于对上一天全国用车需求情况进行数据可视化分析，包括前一天全国需求总量可视化展示、城市级需求量排名可视化分析、需求类型可视化分析以及需求量趋势分析。区域级实时用车需求模块用于展示指定城市的实时订单和实时区域级预测结果。

5.2 系统架构及功能模块设计

STDGAT 用车需求预测系统的整体架构如图 5.1 所示。管理员可在前端界面上直接看到前一天的全国需求数据的可视化展示和实时的订单与区域级预测结果。系统会在长度为 5 小时的时间窗口上来对下一个小时中的全局用车需求量进行实

时的预测，这里将对每个城市来进行单独的预测。管理员可根据需要在前端界面上选择需要展示的城市的需求预测结果，并将其展现在前端界面上。在昨日全国需求数据可视化中，系统将前一天的全国需求数据进行整理和分析，并以可视化的形式展现在前端界面上。

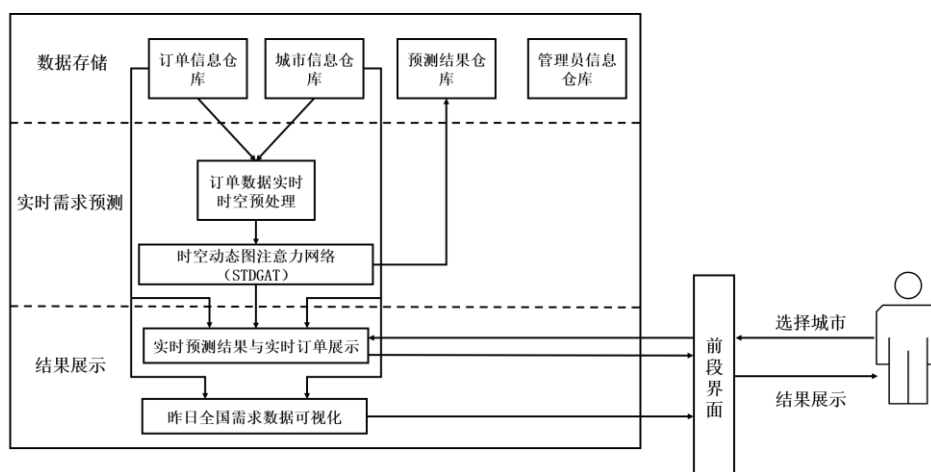


图 5.1 STDGAT 用车需求预测模型架构

Figure 5.1 The architecture of STDGAT vehicle usage demand prediction system

STDGAT 用车需求预测系统包含了前端界面和后台系统。其中前端界面主要用于展示数据可视化结果和预测结果。数据预处理、模型预测等业务逻辑均在后台系统中实现。STDGAT 用车需求预测系统的后台系统可分为如下五个部分：

① 管理员信息管理模块。管理员信息管理模块用于对管理员的信息进行管理包括管理员登录、管理员资料管理和权限分配等。

② 订单数据实时时空预处理模块。订单数据实时时空预处理模块用于对过去一小时内的订单数据进行实时的时空预处理。订单数据使用时空预处理方法在空间和时间两个维度上分别进行预处理，具体的预处理方式如章节 3.3 所述。

③ 时空动态图注意力网络模块 (STDGAT 模块)。STDGAT 模块包含了训练好的 STDGAT 模型，用于实时的对未来一个小时内各个区域的需求量进行预测。传入 STDGAT 模块的数据是经过时空预处理之后的数据。

④ 实时预测结果与实时订单展示模块。该模块包含两个部分，分别为实时预测结果展示和实时订单展示。实时预测结果展示部分将 STDGAT 模块实时预测的各个区域的需求进行展示。实时订单展示部分每小时更新一次，用于展示最新的订单数据。

⑤ 昨日全国需求数据可视化模块。该模块将前一天全国的需求数据进行整理和分析，并将其以可视化的形式展现出来。展示的内容包括全国需求总量可视化

展示、城市需求量排名可视化展示、需求类型占比可视化展示和需求量趋势可视化展示。

5.3 数据库设计

为了实现上述业务逻辑，STDGAT 用车需求预测系统设计了如下数据库表。

① 管理员信息表

管理员信息表用于储存管理员的基本身份信息和权限等级，如表 5.1 所示，管理员信息表包括管理员 id、管理员用户名、管理员登录密码和管理员权限等级四个字段。

表 5.1 管理员信息表

Table 5.1 Administrator information table				
字段名称	字段类型	键值	字段约束	描述
admin_id	varchar(22)	主键	非空	管理员 id
admin_name	varchar(22)		非空	管理员用户名
admin_psw	varchar(22)		非空，加密	管理员登录密码
admin_authority	int(8)		非空	管理员权限等级

② 城市信息表

城市信息表用于存储所有城市的信息，包括城市 id、城市名、城市区域数、城市最大经度值、城市最小经度值、城市最大纬度值、城市最小纬度值字段。

表 5.2 城市信息表

Table 5.2 City information table				
字段名称	字段类型	键值	字段约束	描述
city_id	varchar(22)	主键	非空	城市 id
city_name	varchar(22)		非空	城市名
num_regions	varchar(22)		非空	城市区域数
max_longitude	varchar(22)		非空	城市最大经度值
min_longitude	varchar(22)		非空	城市最小经度值
max_latitude	varchar(22)		非空	城市最大纬度值
min_latitude	varchar(22)		非空	城市最小纬度值

③ 区域信息表

区域信息表用于存储各城市中所有区域的信息，包括区域 id、所属城市 id、区域号、区域最大经度值、区域最小经度值、区域最大纬度值、区域最小纬度值字段。

表 5.3 区域信息表

Table 5.3 Region information table

字段名称	字段类型	键值	字段约束	描述
region_id	varchar(22)	主键	非空	区域 id
city_id	varchar(22)		非空	区域所属城市 id
region_code	varchar(22)		非空	区域在所述城市中的号码
region_max_longitude	varchar(22)		非空	区域最大经度值
region_min_longitude	varchar(22)		非空	区域最小经度值
region_max_latitude	varchar(22)		非空	区域最大纬度值
region_min_latitude	varchar(22)		非空	区域最小纬度值

④ 订单信息表

订单信息表存储了用车订单的相关信息，包括订单 id、订单类型 id、城市 id、起点经度、起点纬度、终点经度、终点纬度、起始时间、终止时间字段。

表 5.4 订单信息表

Table 5.4 Order information table

字段名称	字段类型	键值	字段约束	描述
order_id	varchar(22)	主键	非空	订单 id
city_id	varchar(22)		非空	订单所在城市的 id
starting_longitude	varchar(22)		非空	订单起点经度
starting_latitude	varchar(22)		非空	订单起点纬度
dest_longitude	varchar(22)		非空	订单终点经度
dest_latitude	varchar(22)		非空	订单终点纬度
starting_time	varchar(22)		非空	订单开始的时间
end_time	varchar(22)		非空	订单结束的时间

⑤ 预测结果表

预测结果表用于存储各个城市中各个区域的实时预测结果，包括区域 id、所属的城市 id、区域最大的经度值、区域最小的经度值、区域最大的纬度值、区域最小的纬度值、预测的区域需求值、预测结果时间戳八个字段。

表 5.5 预测结果表

Table 5.5 Prediction results table

字段名称	字段类型	键值	字段约束	描述
region_id	varchar(22)	主键	非空	区域 id
city_id	varchar(22)		非空	区域所属城市 id
region_max_longitude	varchar(22)		非空	区域最大经度值
region_min_longitude	varchar(22)		非空	区域最小经度值
region_max_latitude	varchar(22)		非空	区域最大纬度值
region_min_latitude	varchar(22)		非空	区域最小纬度值
predicted_demand_value	varchar(22)		非空	预测的区域需求值
predicted_timestamp	varchar(22)		非空	预测结果时间戳

5.4 应用原型实现与分析

本小节在本章节上述内容的基础上对 STDGAT 用车需求预测原型系统进行了实现和展示。

① 登录界面。首先，管理员打开系统后会进入登录界面。管理员通过输入用户名和密码来对其身份进行验证。登录界面如图 5.2 所示。



图 5.2 登录界面

Figure 5.2 Login interface

② 昨日全国需求概况界面。在登录成功之后，管理员将进入昨日全国需求概况界面。该界面用于展示前一天的全国需求概况。通过对数据进行可视化处理，该界面分别展示了昨日全国需求总量以及各省市的需求总量、昨日需求量城市排名、昨日需求类型分布图、昨日不同时间的需求量趋势图。该界面每日实时更新一次。



图 5.3 昨日全国需求概况界面

Figure 5.3 Overview interface of yesterday's national demand

③ 区域级实时用车需求预测界面。如图 5.4 所示，区域级实时用车需求预测界面包含两个部分，分别为实时订单展示和区域实时需求预测。用户通过界面最左侧的选项栏来选择需要进行展示的城市。界面中左侧的表格为所选城市的实时订单展示，包括订单 ID、起始区域号、终点区域号、起始时间、终止时间五个字段。右侧表格为区域级需求预测，包括了区域号、过去一小时需求量、过去两小时需求量、过去三小时需求量、过去四小时需求量和实时预测结果六个字段。该界面每小时实时刷新一次，来更新实时订单和区域级预测结果。



图 5.4 区域级实时用车需求预测界面

Figure 5.4 Region-level real-time demand prediction interface

5.5 本章小结

本章节对 STDGAT 共享出行用车需求预测系统原型进行了详细的介绍。本章节首先对共享出行用车需求预测系统的需求进行了详细的分析，随后详细阐述了原型系统的架构以及功能模块的设计。然后，本章节对数据库的设计进行了描述，并在最后对系统原型的实现进行了详细的介绍和分析。

6 总结与展望

6.1 总结

作为城市日常运营的重要组成部分，交通在城市的发展与人们的日常生活中扮演着不可或缺的角色。出行服务作为交通的重要组成部分，在人们的生活中起到了至关重要的作用。作为一种新型出行方式，共享出行在出行服务中的地位不断提高，并逐渐成为主流的出行方式之一。随着共享出行公司的飞速发展，一些低效的运营问题开始逐渐出现在平台的日常运营中，这些问题主要是由于平台资源的分布情况与用户的需求不匹配所造成的。为了使共享出行平台的运营更加高效，一个准确的用车需求预测方法是至关重要的。

图卷积网络（Graph Convolutional Network, GCN）在最新的相关研究工作中得到了广泛应用，但是，现有的基于 GCN 的需求预测方法在进行城市空间相关性建模时，难以使不同的区域（节点）自适应的为不同的邻居区域建立不同的重要性系数。此外，现有的基于 GCN 的时空预测方法在构建城市结构图时，往往是基于区域地理近邻关系来建立图中节点（区域）之间边的关系。这种方式所构建的城市结构图是一种在不同的时间间隔中保持一致的非时间特定性的静态空间图结构，不利于针对不同的时间间隔来动态的提取空间相关性特征。为了解决上述问题，本文提出用于共享出行需求预测的时空动态图卷积网络（Spatial-Temporal Dynamic Graph Attention Networks, STDGAT）。STDGAT 使用图注意力网络（Graph Attention Network, GAT）来自适应的为每个区域的不同邻居区域分配不同的重要性系数，并建立了一种具有时间特定性的基于通勤关系的动态空间图结构，以此在不同的时间间隔中动态的建立具有时间特定性的动态空间关联性。最后，本文基于所提出的 STDGAT 方法，设计并实现了 STDGAT 共享出行用车需求预测系统原型。

本文中的主要工作可以分为以下几个方面：

① 本文指出了共享出行用车需求预测的研究背景与意义，分析了国内外针对共享出行中的用车问题、时空预测问题和图神经网络的相关研究现状。

② 本文提出了一个用于共享出行用车需求预测的 STDGAT 方法。该方法通过使用 GAT 提取空间相关性特征，以此实现了自适应的邻域重要性分配。

③ 本文利用区域间真实的通勤关系，构建了一种具有时间特定性的基于通勤关系的动态空间图结构，以此实现了具有时间特定性的动态空间相关性建模。

④ 本文在一个大规模的共享出行数据集上对本文提出的基于 STDGAT 的共享出行需求预测方法进行实验验证。实验结果表明，该方法在 RMSE、MAPE 和

MAE 三个评价指标上均优于相关前沿方法。

⑤ 本文设计并实现了一个基于 STDGAT 的共享出行用车需求预测的系统原型。

6.2 展望

本文针对现有的需求预测方法所存在的问题，提出了具有针对性的改进方法 STDGAT，并取得了良好可靠的实验结果，并基于此方法建立了共享出行用车需求预测原型系统。虽然实验结果表明，本文所提出的模型具有优异的性能，但是，该模型仍可进一步进行改进，在未来可从以下方面考虑改进方法：

① 本文所提出的 STDGAT 模型没有考虑天气、节假日等信息来作为额外特征来辅助模型进行预测。在未来，可考虑对上述信息进行编码来作为模型的额外输入特征，以此来进一步提高模型的预测准确性。

② 本文的实验部分所采用的共享出行数据集仅包含网约车一项共享出行服务，在未来可考虑建立一个同时包含网约车、共享汽车等多项服务的大规模数据集，并在此数据集上来验证模型的性能。

③ 本文所设计的共享出行用车需求预测原型系统中，仍存在一些对操作人员不友好的界面布局与设计。在未来可考虑进一步明确系统需求，并强化系统的设计，改进系统的功能模块。

参考文献

- [1] Zhan X , Qian X , Ukkusuri S V . A Graph-Based Approach to Measuring the Efficiency of an Urban Taxi Service System[J]. IEEE Transactions on Intelligent Transportation Systems, 2016, 17(9):2479-2489.
- [2] Zhang L, Hu T, Min Y, et al. A taxi order dispatch model based on combinatorial optimization[C]//Proceedings of the 23rd ACM SIGKDD international conference on knowledge discovery and data mining. 2017: 2151-2159.
- [3] Yang H, Lau Y W, Wong S C, et al. A macroscopic taxi model for passenger demand, taxi utilization and level of services[J]. Transportation, 2000, 27(3): 317-340.
- [4] Geng X, Li Y, Wang L, et al. Spatiotemporal multi-graph convolution network for ride-hailing demand forecasting[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33: 3656-3663.
- [5] Chiang M F, Hoang T A, Lim E P. Where are the passengers? a grid-based gaussian mixture model for taxi bookings[C]//Proceedings of the 23rd SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2015: 1-10.
- [6] Moreira-Matias L, Gama J, Ferreira M, et al. Predicting taxi-passenger demand using streaming data[J]. IEEE Transactions on Intelligent Transportation Systems, 2013, 14(3): 1393-1402.
- [7] Shekhar S, Williams B M. Adaptive seasonal time series models for forecasting short-term traffic flow[J]. Transportation Research Record, 2007, 2024(1): 116-125.
- [8] Zhang J, Zheng Y, Qi D, et al. DNN-based prediction model for spatio-temporal data[C]//Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2016: 1-4.
- [9] Zhang J, Zheng Y, Qi D. Deep spatio-temporal residual networks for citywide crowd flows prediction[C]//Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence. 2017: 1655-1661.
- [10] Yao H, Wu F, Ke J, et al. Deep multi-view spatial-temporal network for taxi demand prediction[C]//32nd AAAI Conference on Artificial Intelligence, AAAI 2018. 2018: 2588.
- [11] 张雅洁, 胡文飞. 一种共享单车站点出行预测方法:, CN109559201A[P]. 2019.
- [12] 顾天奇, 庄楚天, 李晋,等. 共享单车总量预测方法及系统:, CN111489039A[P]. 2020.
- [13] Singhvi D, Singhvi S, Frazier P I, et al. Predicting Bike Usage for New York City's Bike Sharing System[C]//AAAI Workshop: Computational Sustainability. 2015.

- [14] Lin L, He Z, Peeta S. Predicting station-level hourly demand in a large-scale bike-sharing network: A graph convolutional neural network approach[J]. *Transportation Research Part C: Emerging Technologies*, 2018, 97: 258-276.
- [15] Luo M, Du B, Klemmer K, et al. D3P: Data-driven demand prediction for fast expanding electric vehicle sharing systems[J]. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2020, 4(1): 1-21.
- [16] Xiao G, Wang R, Zhang C, et al. Demand prediction for a public bike sharing program based on spatio-temporal graph convolutional networks[J]. *Multimedia Tools and Applications*, 2020: 1-19.
- [17] 周龙雨, 常兴甲, 田博. 基于 BP 神经网络的共享单车调度优化[J]. *中国战略新兴产业*, 2017, 24.
- [18] 丁梓文. 共享汽车调度优化策略研究[D]. 长安大学, 2018.
- [19] Liu J, Sun L, Chen W, et al. Rebalancing bike sharing systems: A multi-source data smart optimization[C]//*Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016: 1005-1014.
- [20] Mao D, Li Z, Li H, et al. Bike-Sharing Dynamic Scheduling Model Based on Spatio-Temporal Graph[C]//*2018 IEEE International Conference on Big Data and Smart Computing (BigComp)*. IEEE, 2018: 483-486.
- [21] Dickerson J, Sankararaman K, Srinivasan A, et al. Allocation problems in ride-sharing platforms: Online matching with offline reusable resources[C]//*Proceedings of the AAAI Conference on Artificial Intelligence*. 2018, 32(1).
- [22] Li Y, Zheng Y, Yang Q. Dynamic bike reposition: A spatio-temporal reinforcement learning approach[C]//*Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. 2018: 1724-1733.
- [23] Zhu M, Liu X Y, Wang X. An online ride-sharing path-planning strategy for public vehicle systems[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 20(2): 616-627.
- [24] Pan L, Cai Q, Fang Z, et al. A deep reinforcement learning framework for rebalancing dockless bike sharing systems[C]//*Proceedings of the AAAI conference on artificial intelligence*. 2019, 33(01): 1393-1400.
- [25] Wang D, Cao W, Li J, et al. DeepSD: Supply-demand prediction for online car-hailing services using deep neural networks[C]//*2017 IEEE 33rd international conference on data engineering (ICDE)*. IEEE, 2017: 243-254.
- [26] Pan B, Demiryurek U, Shahabi C. Utilizing real-world transportation data for accurate traffic prediction[C]//*2012 IEEE 12th International Conference on Data Mining*. IEEE, 2012:

- 595-604.
- [27] Wu F, Wang H, Li Z. Interpreting traffic dynamics using ubiquitous urban data[C]//Proceedings of the 24th ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems. 2016: 1-4.
- [28] Lin Z, Feng J, Lu Z, et al. Deepstn+: Context-aware spatial-temporal neural network for crowd flow prediction in metropolis[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33: 1020-1027.
- [29] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [30] Yu R, Li Y, Shahabi C, et al. Deep Learning: A Generic Approach for Extreme Condition Traffic Forecasting[C]// Proceedings of the 2017 SIAM International Conference on Data Mining. 2017: 777-785.
- [31] Zhao J, Xu J, Zhou R, et al. On prediction of user destination by sub-trajectory understanding: A deep learning based approach[C]//Proceedings of the 27th ACM International Conference on Information and Knowledge Management. 2018: 1413-1422.
- [32] Qiu Z, Liu L, Li G, et al. Taxi Origin-Destination Demand Prediction with Contextualized Spatial-Temporal Network[C]//2019 IEEE International Conference on Multimedia and Expo (ICME). 2019: 760-765.
- [33] Wang X, Girshick R, Gupta A, et al. Non-local neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7794-7803.
- [34] 马君, 刘小冬, 孟颖. 基于神经网络的城市交通流预测研究[J]. 电子学报, 2009, 37(5):1092-1094.
- [35] 佟健颀, 黎英, 王一旋. 基于深度残差网络的短时交通流量预测[J]. 电子测量技术, 2019, v.42;No.326(18):90-94.
- [36] 徐彤坤. 基于大数据的出租车需求预测和拼车算法研究[D]. 大连理工大学, 2020.
- [37] 段宗涛, 张凯, 杨云,等. 基于深度CNN-LSTM-ResNet组合模型的出租车需求预测[J]. 交通运输系统工程与信息, 2018.
- [38] 李小妍. 基于图神经网络的交通流量预测[D]. 电子科技大学, 2020.
- [39] Yu B, Yin H, Zhu Z. Spatio-temporal graph convolutional networks: a deep learning framework for traffic forecasting[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence. 2018: 3634-3640.
- [40] Krizhevsky A, Sutskever I, Hinton G. ImageNet classification with deep convolutional neural networks, Proc. Advances in Neural Information Processing System[J]. 2012.
- [41] Sutskever I, Vinyals O, Le Q V. Sequence to sequence learning with neural networks[J].

- Advances in neural information processing systems, 2014, 27: 3104-3112.
- [42] Niepert M, Ahmed M, Kutzkov K. Learning convolutional neural networks for graphs[C]//International conference on machine learning. 2016: 2014-2023.
- [43] Sun C, Shrivastava A, Vondrick C, et al. Relational action forecasting[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 273-283.
- [44] Li C, Cui Z, Zheng W, et al. Spatio-temporal graph convolution for skeleton based action recognition[C]//AAAI. 2018.
- [45] Gori M, Monfardini G, Scarselli F. A new model for learning in graph domains[C]//Proceedings. 2005 IEEE International Joint Conference on Neural Networks, 2005. IEEE, 2005, 2: 729-734.
- [46] Scarselli F, Gori M, Tsoi A C, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2008, 20(1): 61-80.
- [47] Bruna, J., Zaremba, W., Szlam, A., LeCun, Y. Spectral networks and locally connected networks on graphs[C]. International Conference on Learning Representations (ICLR), 2014.
- [48] Defferrard M, Bresson X, Vandergheynst P. Convolutional neural networks on graphs with fast localized spectral filtering[C]. Advances in neural information processing systems, 2016, 29: 3844-3852.
- [49] Kipf, T.N., Welling, M. Semi-supervised classification with graph convolutional networks[C]. International Conference on Learning Representations (ICLR), 2017.
- [50] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[C]. International Conference on Learning Representations (ICLR), 2018.
- [51] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[C]. International Conference on Learning Representations (ICLR), 2015.
- [52] Bahdanau, D., Cho, K., Bengio, Y. Neural machine translation by jointly learning to align and translate[C]. International Conference on Learning Representations (ICLR), 2015.
- [53] Cheng, J., Dong, L., Lapata, M. Long short-term memory-networks for machine reading[C]. Conference on Empirical Methods in Natural Language Processing (EMNLP), 2016, pp. 551–561.
- [54] Chen L, Zhang H, Xiao J, et al. Sca-cnn: Spatial and channel-wise attention in convolutional networks for image captioning[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 5659-5667.
- [55] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [56] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in neural

- information processing systems. 2017: 5998-6008.
- [57] Lin, Z., Feng, M., Santos, C.N.d., Yu, M., Xiang, B., Zhou, B., et al. A structured self-attentive sentence embedding[C]. International Conference on Learning Representations (ICLR), 2017.
- [58] Hochreiter, S., Schmidhuber, J. Long short-term memory[J]. Neural computation, 1997, 9, (8), pp. 1735–1780.
- [59] Hochreiter S, Bengio Y, Frasconi P, et al. Gradient flow in recurrent nets: the difficulty of learning long-term dependencies[J]. 2001.
- [60] SHI, X., Chen, Z., Wang, H., Yeung, D.Y., Wong, W.k., WOO, W.c. Convolutional lstm network: A machine learning approach for precipitation nowcasting[C]. Annual Conference on Neural Information Processing Systems (NeurIPS), 2015, pp. 802–810.
- [61] Kingma, D.P., Ba, J. Adam: A method for stochastic optimization[C]. International Conference on Learning Representations (ICLR), 2015.
- [62] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., et al. Pytorch: An imperative style, high-performance deep learning library[C]. Annual Conference on Neural Information Processing Systems (NeurIPS), 2019, pp. 8026–8037.
- [63] Chen, T., Guestrin, C. Xgboost: A scalable tree boosting system[C]. ACM SIGKDD international conference on knowledge discovery and data mining (SIGKDD), 2016, pp. 785–794.

附 录

A. 作者在攻读硕士学位期间发表的论文目录

- [1] Pian W, Wu Y, Kou Z. STDI-Net: Spatial-Temporal Network with Dynamic Interval Mapping for Bike Sharing Demand Prediction[C]//ACM CIKM Workshop: 9th International Symposium “From Data to Models and Back” (DataMod@CIKM), 2020.
- [2] 骈纬国, 吴映波, 陈蒙, 蔡俊鹏. 一种基于时空动态图注意力网络的共享出行需求预测方法[J]. 电子学报. (已录用)

B. 作者在攻读硕士学位期间参与的科研项目

- [1] 基于互联网的汽车后市场服务平台研发及应用（重庆市技术创新与应用发展专项重点项目），项目号：cstc2019jscx-mbdxX0047
- [2] 汽车产业集聚区域网络协同制造发展模式研究（国家重点研发计划课题），项目号：2019YFB1706101

C. 学位论文数据集

关键词		密级		中图分类号	
用车需求预测；深度学习； 时空数据预测；图神经网络；共享出行		公开		TH	
学位授予单位名称	学位授予单位代码	学位类别		学位级别	
重庆大学	10611	专业学位		硕士	
论文题名		并列题名		论文语种	
基于时空动态图注意力网络的共享出行用车需求预测研究与应用		无		中文	
作者姓名	骈纬国	学号		20183413003t	
培养单位名称		培养单位代码			
重庆大学		10611			
学科专业	研究方向	学制		学位授予年	
车辆工程	汽车智能化与人机交互技术	3 年		2021 年	
论文提交日期	2021 年 6 月	论文总页数		63 页	
导师姓名	吴映波	职称		教授	
答辩委员会主席		熊庆宇			
电子版论文提交格式					
文本 (√) 图像 () 视频 () 音频 () 多媒体 () 其他 ()					

致 谢

至此，三年的研究生生涯即将画上一个圆满的句号。在这三年里，有过迷茫，有过苦恼，也经历了许多挫折，但更多的是收获与希望。在过去的三年里，我学到了很多知识和技能，并经历了严格的科研训练，这一切都使我收获良多。这三年里我结识了许多志同道合的朋友和尽职尽责的老师。在此，我要向过去三年里帮助和关心过我的老师、同学和家人们表示衷心的感谢。

首先，我要感谢我的导师吴映波老师。在我的研究生生涯中，我很幸运遇到了像吴老师这样严谨、知识渊博的老师。正是在吴老师的细心指导和严格要求下，我才能学习到这么多的专业技能和学术知识，并顺利完成毕业论文的撰写。

其次，我要感谢在这三年时光里给予我帮助的小伙伴们。我们一起上课，一起学习，一起讨论问题，一起做实验。感谢你们这三年的陪伴与帮助。

最后，我要感谢我的家人们。感谢你们这二十多年来的照顾与支持，没有你们就没有我的今天，再次感谢你们给我的爱。

另外，我还要感谢重庆大学大数据与软件学院以及汽车协同创新中心对我的培养。

最后的最后，感谢论文评审专家和答辩委员会的专家们，在百忙之中抽出时间来评审我的论文和参与我的答辩。

骈伟国

二〇二一年五月 于重庆